BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC THỦY LỢI

ĐỖ NGUYỄN TRUNG HIẾU

XÂY DỰNG MÔ HÌNH DỰ BÁO GIÁ CỔ PHIẾU VIETCOMBANK DỰA TRÊN HỌC MÁY

Ngành: Công nghệ thông tin

Mã số: 7480201

NGƯỜI HƯỚNG DẪN: TS.Đỗ Trường Xuân

HÀ NỘI, NĂM 2025

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập - Tự do - Hạnh phúc

-----📖-----

NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ và tên: Đỗ Nguyễn Trung Hiếu Hệ đào tạo: Đại học chính quy

Lớp: 63CNTT1 Ngành: Công nghệ thông tin

Khoa: Công nghệ thông tin

1. Tên đề tài tốt nghiệp: XÂY DỰNG MÔ HÌNH DỰ BÁO GIÁ CỔ PHIẾU VIETCOMBANK DỰA TRÊN HỌC MÁY

2. Các tài liệu cơ bản:

[1] C. M. Bishop, *Pattern Recognition and Machine Learning*, New York: Springer, 2006.

[2] G. James, D. Witten, T. Hastie, and R. Tibshirani, “Linear regression,” in *An Introduction to Statistical Learning*, Springer, 2013, pp. 59–122.

[3] Scikit-learn Developers, “Linear models,” *Scikit-learn Documentation*, [Online]. Available: https://scikit-learn.org/stable/modules/linear_model.html. [Accessed: Jul. 3, 2025].

[4] A. Ng, “Machine Learning,” *Coursera Online Course*, Stanford University, 2018. [Online]. Available: https://www.coursera.org/learn/machine-learning

[5] J. Brownlee, “A Gentle Introduction to Linear Regression,” *Machine Learning Mastery*, 2018. [Online]. Available: https://machinelearningmastery.com/linear-regression-for-machine-learning/

[6] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.

[7] S. Rashmi and H. Bhushan, “A Comprehensive Review of Gradient Boosting Algorithms,” *International Journal of Advanced Research in Computer Science*, vol. 9, no. 5, 2018.

[8] Google Developers, “Gradient Boosted Decision Trees,” *Google Developers ML Crash Course*, [Online]. Available: https://developers.google.com/machine-learning/gradient-boosted-trees/. [Accessed: Jul. 3, 2025].

[9] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[10] F. Chollet, *Deep Learning with Python*, 2nd ed., Shelter Island, NY: Manning Publications, 2021.

[11] TensorFlow Developers, “Recurrent Neural Networks (RNN) with Keras,” *TensorFlow Documentation*, [Online]. Available: https://www.tensorflow.org/guide/keras/rnn. .

[12] M. J. Nichols, “Understanding LSTM Networks,” *Colah’s Blog*, 2015. [Online]. Available: https://colah.github.io/posts/2015-08-Understanding-LSTMs/.

[13] N. T. Tuan, “Deep learning cơ bản – Bài 14: Long Short-Term Memory (LSTM),” *nttuan8.com*, [Online]. Available: https://nttuan8.com/bai-14-long-short-term-memory-lstm/.

[14] H. T. X. Nguyen, “Nhóm 9 - Dự đoán giá chứng khoán,” *YouTube*, 2023. [Online Video]. Available: https://youtu.be/d8h3k4W7a8M?si=bshT2j7Os7-u4rFg.

[15] TUYEN268KK, “Prediction of Vietcombank stock prices by SARIMA,” *Kaggle Notebooks*, 2024. [Online]. Available: https://www.kaggle.com/code/tuyen268kk/prediction-of-vietcombank-stock-prices-by-sarima.

3. Nội dung các phần thuyết minh và tính toán:

Nội dung các phần	Tỷ lệ (%)
Chương 1: tổng quan về dự án dự báo giá cổ phiếu vcb	20%
Chương 2: các kĩ thuật sử dụng	30%
Chương 3: triển khai hệ thống và giao diện người dùng	40%
Chương 4: kết quả đánh giá các mô hình	10%

4. Giáo viên hướng dẫn từng phần:

Nội dung các phần	Giáo viên hướng dẫn
Chương 1: tổng quan về dự án dự báo giá cổ phiếu vcb	TS. Đỗ Trường Xuân
Chương 2: các kĩ thuật sử dụng	TS. Đỗ Trường Xuân
Chương 3: Triển khai hệ thống và giao diện người dùng	TS. Đỗ Trường Xuân
Chương 4: kết quả đánh giá các mô hình	TS. Đỗ Trường Xuân

5. Ngày giao nhiệm vụ đồ án tốt nghiệp

Ngày ..... tháng ..... năm 2025

Trưởng Bộ môn	**Giáo viên hướng dẫn**
(Ký và ghi rõ Họ tên)	*(Ký và ghi rõ Họ tên)*
	TS. Đỗ Trường Xuân

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng thi tốt nghiệp của Khoa thông qua.

TRƯỜNG ĐẠI HỌC THUỶ LỢI

KHOA CÔNG NGHỆ THÔNG TIN

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

TÊN ĐỀ TÀI: XÂY DỰNG MÔ HÌNH DỰ BÁO GIÁ CỔ PHIẾU VIETCOMBANK DỰA TRÊN HỌC MÁY

Sinh viên thực hiện: Đỗ Nguyễn Trung Hiếu

Lớp: 63CNTT1

Mã sinh viên: 2151060219

Giáo viên hướng dẫn: TS. Đỗ Trường Xuân

TÓM TẮT ĐỀ TÀI

Biến động giá cổ phiếu là một trong những mối quan tâm hàng đầu của nhà đầu tư trên thị trường chứng khoán. Việc dự báo xu hướng giá cổ phiếu không chỉ hỗ trợ ra quyết định đầu tư mà còn góp phần tối ưu hóa danh mục và giảm thiểu rủi ro. Trong bối cảnh dữ liệu tài chính ngày càng phong phú và biến động phi tuyến, các phương pháp truyền thống trở nên kém hiệu quả.

Với sự phát triển mạnh mẽ của học máy (Machine Learning) và học sâu (Deep Learning), việc ứng dụng các mô hình như Linear Regression, Random Forest, Gradient Boosting, và LSTM để dự báo giá cổ phiếu đang trở thành xu hướng phổ biến và hiệu quả hơn. Đề tài này tập trung xây

dựng và so sánh các mô hình học máy nhằm dự báo giá cổ phiếu ngân hàng Vietcombank (VCB) dựa trên dữ liệu lịch sử.

Các nội dung chính bao gồm:

- Thu thập và xử lý dữ liệu giá cổ phiếu Vietcombank.
- Trích xuất đặc trưng, tạo các biến kỹ thuật như MA5, MA20.
- Huấn luyện các mô hình học máy: Linear Regression, Random Forest, Gradient Boosting và LSTM.
- So sánh, đánh giá độ chính xác các mô hình bằng các chỉ số RMSE, MAE, R^2.
- Triển khai giao diện ứng dụng dự báo bằng CustomTkinter.

Kết quả kỳ vọng là lựa chọn được mô hình dự báo có độ chính xác cao, từ đó triển khai thành ứng dụng đơn giản hỗ trợ nhà đầu tư theo dõi và ước lượng xu hướng giá cổ phiếu VCB trong ngắn hạn.

LỜI CAM ĐOAN

Tôi xin cam đoan đây là Đồ án tốt nghiệp do chính tôi thực hiện. Các số liệu, kết quả trình bày trong đồ án là trung thực và chưa từng được sử dụng trong bất kỳ đồ án nào khác. Trong quá trình thực hiện, nếu có sử dụng tài liệu tham khảo, tôi đã trích dẫn rõ nguồn theo đúng quy định.

Hà Nội, năm 2025

Sinh viên thực hiện

Đỗ Nguyễn Trung Hiếu

LỜI CẢM ƠN

Xin gửi lời cảm ơn chân thành và sâu sắc nhất tới các thầy cô trong bộ môn đã tận tình giảng dạy, truyền đạt kiến thức và hướng dẫn trong suốt quá trình học tập cũng như thực hiện đồ án này. Đặc biệt, xin cảm ơn thầy Đỗ Trường Xuân đã luôn nhiệt tình hỗ trợ, định hướng, giải đáp những thắc mắc và tạo điều kiện thuận lợi để em hoàn thành tốt đề tài.

Những ý kiến đóng góp quý báu, sự động viên và chỉ bảo tận tình của các thầy cô là nguồn động lực to lớn giúp em vượt qua những khó khăn, thử thách trong quá trình thực hiện đồ án.

Một lần nữa, em xin chân thành cảm ơn các thầy cô và mong tiếp tục nhận được sự quan tâm, giúp đỡ của thầy cô trong những chặng đường học tập tiếp theo. Xin trân trọng cảm ơn!

DANH MỤC HÌNH ẢNH

STT	Tên hình	Trang
Hình 2.1	Giá đóng cửa theo thời gian	14
Hình 2.2	Phân phối giá đóng cửa	14
Hình 2.3	Ma trận tương quan	15
Hình 2.4	Cấu trúc tế bào LSTM	24
Hình 3.1	Giao diện ứng dụng dự báo giá cổ phiếu	36
Hình 4.1	Biểu đồ so sánh giá dự báo và giá thực tế (Gradient Boosting)	43
Hình 4.2	Biểu đồ sai số dự báo của mô hình LSTM	44
Hình PL.1	Ảnh chụp dự báo ngày 30/6/2025	47
Hình PL.2	Ảnh chụp dự báo ngày 1/7/2025	48

DANH MỤC BẢNG BIỂU

STT Tên bảng Trang

Bảng 3.1 Cấu hình môi trường thực nghiệm..... 27

Bảng 3.2 Kết quả đánh giá mô..... 32

Bảng 3.3 So sánh đặc điểm các mô hình học máy..... 33

Bảng 4.1 So sánh chỉ số RMSE, MAE, R^2 giữa các mô hình..... 42

DANH MỤC TỪ VIẾT TẮT VÀ GIẢI THÍCH THUẬT NGỮ

Từ viết tắt / Thuật ngữ	**Giải thích ngắn gọn**
AI (*Artificial Intelligence*)	Trí tuệ nhân tạo – mô phỏng khả năng suy nghĩ của con người bằng máy móc
ML (*Machine Learning*)	Học máy – hệ thống tự học từ dữ liệu để đưa ra dự đoán hoặc quyết định
DL (*Deep Learning*)	Học sâu – mô hình học máy nhiều lớp (thường dùng mạng nơ-ron)
LSTM (*Long Short-Term Memory*)	Mạng nơ-ron hồi tiếp có khả năng ghi nhớ dài hạn, dùng trong chuỗi thời gian
RNN (*Recurrent Neural Network*)	Mạng nơ-ron hồi tiếp – dùng cho dữ liệu tuần tự như văn bản, chuỗi
GUI (*Graphical User Interface*)	Giao diện người dùng đồ họa – nơi người dùng tương tác với hệ thống
Flask	Framework web nhẹ của Python – dùng để tích hợp mô hình AI lên web
MA_5 / MA_20 (*Moving Average 5/20 days*)	Trung bình động 5 và 20 ngày – chỉ báo xu hướng giá
RMSE (*Root Mean Square Error*)	Sai số bình phương trung bình căn bậc hai – đo độ lệch giữa dự báo và thực tế
MAE (*Mean Absolute Error*)	Sai số tuyệt đối trung bình – trung bình khoảng cách tuyệt đối giữa dự báo và thực tế
R^2 (*R-squared*)	Hệ số xác định – đánh giá mức độ mô hình phù hợp với dữ liệu

EDA (*Exploratory Data Analysis*)	Phân tích dữ liệu khám phá – bước đầu phân tích, trực quan dữ liệu
Feature	Đặc trưng – dữ liệu đầu vào mô hình học từ đó
Target (*Label*)	Biến mục tiêu – giá trị mô hình cần dự đoán (ví dụ: giá đóng cửa)
Epoch	Một vòng huấn luyện qua toàn bộ dữ liệu
Batch size	Số mẫu xử lý trong mỗi lần cập nhật mô hình

MỤC LỤC

DANH MỤC HÌNH ẢNH iii
DANH MỤC BẢNG BIỂU iv
DANH MỤC TỪ VIẾT TẮT VÀ GIẢI THÍCH THUẬT NGỮ.....v
CHƯƠNG 1: TỔNG QUAN VỀ DỰ ÁN DỰ BÁO GIÁ CỔ PHIẾU VCB 1
1.1. Giới thiệu về bài toán dự báo giá cổ phiếu 1
1.2. Ý nghĩa thực tiễn và ứng dụng của hệ thống 2
1.3. Tổng quan nghiên cứu.....3
1.3.1. Tổng quan về dữ liệu sử dụng.....3
1.3.2. Các phương pháp truyền thống 5
1.3.3. Mô hình học máy cổ điển.....6
1.3.4. Mô hình học sâu (Deep learning).....7
1.3.5. Nghiên cứu liên quan trong và ngoài nước 7
1.3.6. Đánh giá tổng quan 8
1.4. Ý nghĩa và mục tiêu 8
1.4.1 Ý nghĩa thực tiễn.....8
1.4.2. Mục tiêu cụ thể.....9
1.4.3. Định hướng phát triển mở rộng.....10
CHƯƠNG 2: CÁC KĨ THUẬT SỬ DỤNG 11
2.1. Phương pháp thu thập và xử lý dữ liệu 11
2.1.1. Nguồn dữ liệu.....11
2.1.2. Tiền xử lý dữ liệu.....11
2.1.3. Phân tích dữ liệu khám phá (EDA).....13
2.2. Mô hình trí tuệ nhân tạo áp dụng 17
2.2.1. Linear Regression 17
2.2.2. Random Forest Regressor 19
2.2.3. Gradient Boosting Regressor (GBoost) 20
2.2.4. LSTM (Long Short-Term Memory) 22
2.3. Tiêu chí đánh giá mô hình.....24

CHƯƠNG 3: TRIỂN KHAI HỆ THỐNG VÀ GIAO DIỆN NGƯỜI DÙNG 26
3.1. Môi trường thực nghiệm 26
3.1.1 Cấu hình 26
3.1.2. Dữ liệu sử dụng 26
3.1.3. Cài đặt mô hình và huấn luyện.....28
3.1.4. Kết quả mô hình 30
3.1.5. Phân tích và lựa chọn mô hình chính 31
3.2. Thiết kế giao diện web dự báo 32
3.2.1. Nguyên tắc thiết kế giao diện.....32
3.2.2. Các thành phần chính của giao diện.....33
3.2.3. Công nghệ và quá trình xây dựng giao diện 34
3.2.4. Vai trò của giao diện trong hệ thống dự báo.....34
3.3. Tích hợp mô hình AI vào ứng dụng Flask 35
3.3.1. Chuẩn bị mô hình và môi trường tích hợp 35
3.3.2. Xây dựng cấu trúc ứng dụng Flask 35
3.3.3. Quy trình xử lý yêu cầu dự báo.....35
3.3.4. Xử lý các vấn đề thực tiễn khi tích hợp 36
3.3.5. Mở rộng và bảo trì hệ thống.....37
3.4. Đề xuất phát triển 37
3.4.1. Bài học kinh nghiệm 37
3.4.2. Đề xuất phát triển hệ thống trong tương lai 38
CHƯƠNG 4: KẾT QUẢ ĐÁNH GIÁ CÁC MÔ HÌNH 39
TÀI LIỆU THAM KHẢO.....42
PHỤ LỤC.....44

CHƯƠNG 1: TỔNG QUAN VỀ DỰ ÁN DỰ BÁO GIÁ CỔ PHIẾU VCB

1.1. Giới thiệu về bài toán dự báo giá cổ phiếu

Thị trường chứng khoán là một trong những kênh đầu tư tài chính quan trọng và phổ biến nhất trên thế giới hiện nay. Giá cổ phiếu trên thị trường luôn biến động không ngừng dưới tác động của nhiều yếu tố như tình hình kinh tế vĩ mô, kết quả kinh doanh của doanh nghiệp, tâm lý nhà đầu tư, các chính sách của Nhà nước, cũng như các sự kiện bất ngờ trong và ngoài nước. Chính vì vậy, việc dự báo giá cổ phiếu luôn là một bài toán khó, thu hút sự quan tâm nghiên cứu của các nhà khoa học, chuyên gia tài chính và các nhà đầu tư.

Bài toán dự báo giá cổ phiếu (Stock Price Prediction) là quá trình sử dụng các phương pháp phân tích dữ liệu, thống kê, toán học và gần đây là các kỹ thuật trí tuệ nhân tạo để dự đoán giá trị tương lai của một cổ phiếu dựa trên các dữ liệu lịch sử và các yếu tố liên quan. Mục tiêu của bài toán này là giúp các nhà đầu tư đưa ra quyết định mua, bán hoặc nắm giữ cổ phiếu một cách hợp lý, tối ưu hóa lợi nhuận và giảm thiểu rủi ro.

Trước đây, các phương pháp dự báo truyền thống như phân tích kỹ thuật (Technical Analysis), phân tích cơ bản (Fundamental Analysis), các mô hình chuỗi thời gian (ARIMA, GARCH, v.v.) thường được sử dụng để dự báo giá cổ phiếu. Tuy nhiên, các phương pháp này có những hạn chế nhất định, đặc biệt là trong việc xử lý các dữ liệu phi tuyến tính, phức tạp và chịu ảnh hưởng của nhiều yếu tố ngoại sinh.

Trong những năm gần đây, sự phát triển mạnh mẽ của lĩnh vực trí tuệ nhân tạo (AI) và học máy (Machine Learning) đã mở ra nhiều hướng tiếp cận mới cho bài toán dự báo giá cổ phiếu. Các mô hình học máy hiện đại như Random Forest, Gradient Boosting, Neural Networks, LSTM, v.v. có khả năng học hỏi từ dữ liệu lớn, phát hiện các quy luật tiềm ẩn và mối quan hệ phức tạp giữa các biến số mà các phương pháp truyền thống khó nhận biết. Nhờ đó, độ chính xác của dự báo được nâng cao đáng kể.

Tuy nhiên, bài toán dự báo giá cổ phiếu vẫn còn nhiều thách thức do tính chất biến động mạnh, khó lường và chịu ảnh hưởng của nhiều yếu tố không thể định lượng được. Việc lựa chọn mô hình phù hợp, xử lý dữ liệu hiệu quả và đánh giá kết quả dự báo một cách khách quan là những vấn đề then chốt cần được quan tâm trong quá trình nghiên cứu và ứng dụng thực tiễn.

Trong khuôn khổ đồ án này, em tập trung nghiên cứu và xây dựng hệ thống dự báo giá cổ phiếu VCB dựa trên dữ liệu lịch sử và các mô hình học máy hiện đại. Qua đó, em mong muốn góp phần tìm hiểu, ứng dụng các phương pháp mới vào lĩnh vực tài chính, đồng thời nâng cao kỹ năng phân tích, xử lý dữ liệu và phát triển mô hình dự báo thực tiễn.

1.2. Ý nghĩa thực tiễn và ứng dụng của hệ thống

Việc xây dựng hệ thống dự báo giá cổ phiếu ứng dụng trí tuệ nhân tạo mang lại nhiều ý nghĩa thực tiễn quan trọng, không chỉ đối với các nhà đầu tư cá nhân mà còn đối với các tổ chức tài chính, doanh nghiệp và cả lĩnh vực nghiên cứu khoa học dữ liệu.

Trước hết, đối với các nhà đầu tư, hệ thống dự báo giá cổ phiếu là một công cụ hỗ trợ đắc lực trong quá trình ra quyết định đầu tư. Thị trường chứng khoán luôn biến động phức tạp, chịu ảnh hưởng của nhiều yếu tố kinh tế, chính trị, xã hội và tâm lý nhà đầu tư. Việc dựa vào cảm tính hoặc kinh nghiệm cá nhân thường tiềm ẩn nhiều rủi ro. Hệ thống dự báo dựa trên dữ liệu lịch sử và các mô hình học máy hiện đại sẽ giúp nhà đầu tư có cái nhìn khách quan, khoa học hơn về xu hướng giá cổ phiếu trong tương lai, từ đó đưa ra các quyết định mua, bán hoặc nắm giữ cổ phiếu một cách hợp lý, tối ưu hóa lợi nhuận và giảm thiểu rủi ro.

Đối với các tổ chức tài chính như ngân hàng, công ty chứng khoán, quỹ đầu tư, hệ thống dự báo giá cổ phiếu còn đóng vai trò quan trọng trong việc xây dựng các chiến lược đầu tư, quản trị danh mục, kiểm soát rủi ro và phát triển các sản phẩm tài chính mới. Việc ứng dụng trí tuệ nhân tạo vào phân tích và dự báo thị trường giúp các tổ chức này nâng cao năng lực cạnh tranh, tối ưu hóa hoạt động kinh doanh và phục vụ khách hàng tốt hơn.

Bên cạnh đó, hệ thống dự báo giá cổ phiếu còn có ý nghĩa lớn trong lĩnh vực nghiên cứu khoa học dữ liệu và trí tuệ nhân tạo. Việc xây dựng, huấn luyện và đánh giá các mô hình dự báo trên dữ liệu thực tế giúp sinh viên, nhà nghiên cứu rèn luyện kỹ năng phân tích dữ liệu, xử lý dữ liệu thời gian, lựa chọn và tối ưu hóa mô hình học máy. Đây cũng là cơ hội để tiếp cận các công nghệ mới, hiểu rõ hơn về các thách thức thực tiễn khi triển khai AI vào lĩnh vực tài chính, từ đó phát triển các giải pháp sáng tạo, hiệu quả hơn trong tương lai.

Ngoài ra, hệ thống còn có thể được mở rộng và tích hợp vào các nền tảng giao dịch trực tuyến, ứng dụng di động, giúp người dùng dễ dàng tiếp cận và sử dụng các công cụ dự báo thông minh mọi lúc, mọi nơi. Điều này góp phần thúc đẩy quá trình chuyển đổi số trong lĩnh vực tài chính, nâng cao trải nghiệm người dùng và tạo ra giá trị gia tăng cho toàn xã hội.

Tóm lại, hệ thống dự báo giá cổ phiếu ứng dụng trí tuệ nhân tạo không chỉ mang lại lợi ích thiết thực cho các nhà đầu tư và tổ chức tài chính, mà còn góp phần thúc đẩy sự phát triển của khoa học công nghệ, nâng cao chất lượng nguồn nhân lực và hỗ trợ quá trình hiện đại hóa thị trường tài chính Việt Nam.

1.3. Tổng quan nghiên cứu

Dự báo giá cổ phiếu là một trong những bài toán kinh điển và thách thức nhất trong lĩnh vực tài chính – dữ liệu. Với bản chất biến động phức tạp, khó kiểm soát và chịu ảnh hưởng từ nhiều yếu tố ngoại sinh như chính trị, kinh tế vĩ mô, tâm lý thị trường, việc dự đoán chính xác giá cổ phiếu luôn là mục tiêu hướng tới của các nhà đầu tư, chuyên gia tài chính và các nhà nghiên cứu trong lĩnh vực học máy.

Trong nhiều năm qua, đã có rất nhiều hướng tiếp cận được đề xuất và triển khai để giải quyết bài toán này. Tựu chung lại, có thể chia thành ba nhóm chính: (1) các phương pháp truyền thống, (2) các mô hình học máy cổ điển và (3) các mô hình học sâu hiện đại.

1.3.1. Tổng quan về dữ liệu sử dụng

Dữ liệu là yếu tố nền tảng đóng vai trò cốt lõi quyết định chất lượng và độ chính xác của bất kỳ hệ thống học máy nào, đặc biệt là trong các lĩnh vực nhạy cảm và

biến động mạnh như tài chính – chứng khoán. Trong khuôn khổ đồ án này, em lựa chọn và sử dụng bộ dữ liệu lịch sử giá cổ phiếu của Ngân hàng TMCP Ngoại thương Việt Nam (VCB), một trong những mã cổ phiếu bluechip có mức độ thanh khoản cao và ảnh hưởng lớn đến chỉ số VN-Index của thị trường chứng khoán Việt Nam.

Việc lựa chọn VCB làm đối tượng nghiên cứu không chỉ mang tính đại diện mà còn phù hợp với tính thực tiễn cao khi đây là một trong những mã được nhà đầu tư quan tâm nhất trong thời gian qua. Dữ liệu được thu thập từ các nguồn uy tín như Yahoo Finance, Investing.com, hoặc MarketWatch... nhằm đảm bảo tính chính xác, liên tục và toàn vẹn của thông tin. Phạm vi dữ liệu trải dài từ tháng 1 năm 2020 đến tháng 5 năm 2025, với tần suất theo ngày giao dịch. Điều này đảm bảo cung cấp đủ chiều sâu thời gian để các mô hình học máy như LSTM có thể học được mối liên hệ dài hạn giữa các phiên giao dịch.

Mỗi bản ghi trong tập dữ liệu tương ứng với một phiên giao dịch và chứa các trường thông tin chính bao gồm:

DATE: Ngày giao dịch, định dạng chuẩn (yyyy-mm-dd) giúp xác định thứ tự thời gian.

OPEN: Giá mở cửa trong phiên.

HIGH: Giá cao nhất trong ngày.

LOW: Giá thấp nhất trong ngày.

CLOSE: Giá đóng cửa – biến mục tiêu mà mô hình sẽ dự báo.

VOLUME: Khối lượng giao dịch cổ phiếu trong phiên.

Ngoài các trường cơ bản, để nâng cao khả năng học của mô hình, tác giả đã xây dựng thêm một số đặc trưng kỹ thuật (technical features) như:

Return_1d: Lợi suất một ngày (1-day return), phản ánh tốc độ tăng/giảm so với phiên trước đó.

MA_5 và MA_20: Trung bình động 5 và 20 ngày, thể hiện xu hướng ngắn và trung hạn.

Volume Moving Average: Trung bình động khối lượng – phản ánh xu hướng giao dịch.

Trước khi đưa vào huấn luyện mô hình, dữ liệu được xử lý và kiểm tra chất lượng nghiêm ngặt. Quá trình xử lý bao gồm:

Kiểm tra và xử lý giá trị thiếu (missing values)

Phát hiện và loại bỏ ngoại lệ (outliers)

Chuẩn hóa dữ liệu (MinMaxScaler) – đặc biệt quan trọng với mô hình LSTM

Tạo cửa sổ thời gian (windowing) cho các mô hình chuỗi như LSTM (ví dụ: 60 ngày để dự đoán ngày thứ 61)

Việc xây dựng bộ đặc trưng kỹ thuật giúp mô hình không chỉ dựa vào giá đơn thuần mà còn nắm bắt được xu hướng, nhịp điệu thị trường và tâm lý nhà đầu tư. Đặc biệt, với mô hình LSTM, các đặc trưng kỹ thuật đóng vai trò như các tín hiệu bổ trợ giúp cải thiện độ chính xác dự báo.

Ngoài ra, dữ liệu còn được chia thành hai tập: huấn luyện (train) và kiểm tra (test) với tỷ lệ 80/20 nhằm đảm bảo đánh giá khách quan hiệu quả mô hình. Trong một số thử nghiệm, tập kiểm tra còn được giữ làm tập dự báo tương lai hoàn toàn mới nhằm kiểm tra khả năng tổng quát hoá của mô hình.

Tổng thể, việc chuẩn bị và xử lý dữ liệu không chỉ là một bước kỹ thuật cần thiết mà còn là yếu tố quyết định đến độ tin cậy của toàn bộ quá trình xây dựng mô hình học máy. Với bộ dữ liệu được chuẩn bị cẩn thận, chất lượng cao và giàu thông tin như vậy, hệ thống có thể phát huy tối đa khả năng học và dự báo, qua đó đem lại những giá trị thực tiễn cho nhà đầu tư và thị trường tài chính.

1.3.2. Các phương pháp truyền thống

Các phương pháp truyền thống thường dựa vào phân tích thống kê hoặc phân tích kỹ thuật. Một số kỹ thuật phổ biến bao gồm:

- **Phân tích kỹ thuật**: sử dụng các chỉ báo như MA (Moving Average), MACD (Moving Average Convergence Divergence), RSI (Relative Strength Index) để tìm kiếm tín hiệu mua – bán. Tuy nhiên, các chỉ báo này mang tính quy tắc cứng, thiếu khả năng thích ứng với sự thay đổi liên tục của thị trường.

- **Phân tích chuỗi thời gian**: các mô hình như ARIMA (Auto-Regressive Integrated Moving Average), SARIMA (Seasonal ARIMA), GARCH (Generalized Autoregressive Conditional Heteroskedasticity) từng rất phổ biến trong phân tích và dự báo giá. Những mô hình này chủ yếu dựa vào giả định tuyến tính và tính dừng của dữ liệu, do đó thường không đủ linh hoạt khi xử lý các hiện tượng phi tuyến hoặc chuỗi có xu hướng mạnh như giá cổ phiếu.

1.3.3. Mô hình học máy cổ điển

Nhằm khắc phục nhược điểm của các mô hình truyền thống, các phương pháp học máy (machine learning) đã được ứng dụng rộng rãi. Một số mô hình tiêu biểu bao gồm:

- **Linear Regression**: đây là mô hình nền tảng dùng để thiết lập baseline. Tuy đơn giản, nhưng mô hình này chỉ phù hợp với dữ liệu tuyến tính và không xử lý được các yếu tố phi tuyến hoặc tính phụ thuộc theo thời gian.

- **Random Forest**: là một mô hình tổ hợp (ensemble learning) gồm nhiều cây quyết định, có khả năng học được mối quan hệ phi tuyến giữa các đặc trưng đầu vào và giá cổ phiếu. Random Forest ít nhạy cảm với nhiễu và thường cho kết quả ổn định.

- **Gradient Boosting**: mô hình tăng cường dần (boosting), nổi bật với các thuật toán như XGBoost, LightGBM, CatBoost. Các mô hình này hoạt động theo cơ chế liên tục học từ sai số của mô hình trước để cải thiện kết quả. Gradient Boosting thường cho độ chính xác rất cao nếu được tối ưu tham số tốt.

Các mô hình học máy cổ điển này cho phép khai thác dữ liệu đa chiều, kết hợp nhiều đặc trưng kỹ thuật, nhưng lại thiếu khả năng ghi nhớ và xử lý chuỗi thời gian liên tục, điều rất cần thiết trong bối cảnh dữ liệu tài chính.

1.3.4. Mô hình học sâu (Deep learning)

Học sâu là bước tiến lớn trong việc giải quyết các bài toán có dữ liệu lớn và cấu trúc phức tạp như hình ảnh, âm thanh và đặc biệt là chuỗi thời gian. Trong lĩnh vực tài chính, học sâu cho phép mô hình học được các quy luật ẩn sâu, phi tuyến mà các mô hình truyền thống không thể khai thác.

- **LSTM (Long Short-Term Memory)**: là một kiến trúc đặc biệt của mạng nơ-ron hồi tiếp (RNN), có khả năng ghi nhớ thông tin dài hạn và ngắn hạn trong chuỗi dữ liệu. Đây là mô hình rất phù hợp để dự báo chuỗi thời gian như giá cổ phiếu, do có thể khai thác mối quan hệ giữa các phiên giao dịch liên tiếp trong thời gian dài.

- **GRU (Gated Recurrent Unit)**: là biến thể nhẹ hơn của LSTM, có hiệu suất tốt trong nhiều trường hợp nhưng ít phổ biến hơn LSTM trong dự báo tài chính.

- **Transformer và Attention Mechanism**: là các mô hình tiên tiến, cho phép mô hình "tập trung" vào những điểm quan trọng trong chuỗi. Mặc dù chủ yếu được sử dụng trong NLP (xử lý ngôn ngữ tự nhiên), nhưng gần đây các mô hình như Informer, TimesNet… đã chứng minh hiệu quả trong dự báo chuỗi thời gian phức tạp như giá cổ phiếu hoặc giá năng lượng.

1.3.5. Nghiên cứu liên quan trong và ngoài nước

Nhiều nghiên cứu quốc tế đã chứng minh tính hiệu quả của các mô hình học sâu trong dự báo tài chính. Chẳng hạn, bài báo “Stock Market Prediction Using LSTM Recurrent Neural Network” (Fischer & Krauss, 2018) cho thấy LSTM vượt trội so với các mô hình tuyến tính trong dự báo giá cổ phiếu S&P500. Tại Việt Nam, các luận văn và đề tài từ các trường như ĐH Kinh tế Quốc dân, ĐH Bách Khoa, Học viện Ngân hàng… cũng đã thử nghiệm với các mô hình RF, GBoost, LSTM trên dữ liệu cổ phiếu như VNM, VCB, GAS, CTG…

1.3.6. Đánh giá tổng quan

Các mô hình truyền thống như ARIMA, MA, RSI tuy đơn giản nhưng dễ bị nhiễu và không thích ứng được với thị trường biến động. Mô hình học máy cổ điển như Random Forest, Gradient Boosting xử lý dữ liệu phi tuyến tốt hơn nhưng vẫn còn hạn chế trong việc khai thác tính chuỗi.

LSTM nổi bật nhờ khả năng học phụ thuộc dài hạn, đặc biệt hữu ích với dữ liệu cổ phiếu theo ngày. Tuy nhiên, LSTM yêu cầu lượng dữ liệu lớn, thời gian huấn luyện lâu hơn và cần kỹ năng xử lý chuỗi phức tạp hơn. Do đó, việc so sánh hiệu quả giữa các mô hình là rất cần thiết để chọn được mô hình tối ưu cho từng loại dữ liệu và mục tiêu cụ thể.

1.4. Ý nghĩa và mục tiêu

1.4.1 Ý nghĩa thực tiễn

Trong bối cảnh nền kinh tế ngày càng phát triển, thị trường tài chính – đặc biệt là thị trường chứng khoán – trở thành một trong những kênh đầu tư hấp dẫn nhất tại Việt Nam. Việc đưa ra quyết định đầu tư hiệu quả không chỉ đòi hỏi kiến thức chuyên môn mà còn cần đến khả năng phân tích dữ liệu, nhận diện xu hướng thị trường và dự đoán chính xác giá cổ phiếu trong tương lai.

Tuy nhiên, đặc thù của thị trường chứng khoán là tính biến động cao, bị ảnh hưởng bởi nhiều yếu tố như kinh tế vĩ mô, chính sách tài chính, tâm lý nhà đầu tư, các biến cố quốc tế… Do đó, việc dự báo chính xác giá cổ phiếu là một thách thức lớn.

Sự phát triển của trí tuệ nhân tạo (AI) và học máy (Machine Learning) đã mở ra hướng tiếp cận mới cho bài toán này. Thay vì chỉ sử dụng các phương pháp thống kê truyền thống hay phân tích kỹ thuật, việc áp dụng các mô hình học máy cho phép xử lý lượng dữ liệu lớn, học các mối quan hệ phức tạp và phi tuyến tính giữa các biến trong dữ liệu tài chính.

Đặc biệt, với sự xuất hiện của các mô hình học sâu như LSTM (Long Short-Term Memory), khả năng ghi nhớ chuỗi thời gian và khai thác mối liên hệ dài hạn trong

dữ liệu đã được cải thiện đáng kể. Điều này phù hợp với đặc tính tuần hoàn, lặp lại và xu hướng của dữ liệu giá cổ phiếu.

Đồ án "Dự báo giá cổ phiếu Vietcombank bằng các mô hình học máy" không chỉ mang lại giá trị học thuật trong việc nghiên cứu, thử nghiệm và so sánh hiệu quả của các mô hình như Linear Regression, Random Forest, Gradient Boosting và LSTM, mà còn có ý nghĩa thực tiễn trong việc ứng dụng công nghệ để hỗ trợ ra quyết định đầu tư tài chính thông minh hơn.

1.4.2. Mục tiêu cụ thể

Mục tiêu chính của đồ án là xây dựng hệ thống dự báo giá cổ phiếu mã VCB (Ngân hàng TMCP Ngoại thương Việt Nam) dựa trên dữ liệu lịch sử và các mô hình học máy khác nhau, từ đó đánh giá và so sánh độ chính xác của từng mô hình. Cụ thể, các mục tiêu bao gồm:

- **Thu thập và xử lý dữ liệu** giá cổ phiếu VCB từ năm 2020 đến 2025, bao gồm các đặc trưng như: giá mở cửa, giá đóng cửa, giá cao nhất, thấp nhất, khối lượng giao dịch.
- **Tiền xử lý dữ liệu** bao gồm chuẩn hóa, xử lý thiếu giá trị, tạo các đặc trưng kỹ thuật như MA5, MA20 (trung bình động), tỷ suất sinh lời hằng ngày…
- **Áp dụng và huấn luyện các mô hình học máy** gồm:
    - Linear Regression – để thiết lập baseline đơn giản
    - Random Forest và Gradient Boosting – các mô hình cây mạnh, học phi tuyến
    - LSTM – mạng nơ-ron học sâu xử lý chuỗi thời gian
- **So sánh hiệu suất của các mô hình** thông qua các chỉ số đánh giá như:
    - RMSE (Root Mean Square Error)
    - MAE (Mean Absolute Error)
    - R^2 Score (Hệ số xác định)

- **Đưa ra phân tích, kết luận và đề xuất** mô hình phù hợp nhất cho bài toán dự báo giá cổ phiếu ngắn hạn tại Việt Nam.
- **Xây dựng giao diện người dùng (GUI)** hoặc ứng dụng thử nghiệm (bằng tkinter, flask, customtkinter...) để nhà đầu tư có thể sử dụng mô hình một cách trực quan và dễ dàng.

1.4.3. Định hướng phát triển mở rộng

Sau khi hoàn thành đồ án, hệ thống có thể được phát triển thêm:

- Dự báo cho nhiều mã cổ phiếu khác nhau (BID, CTG, TCB…)
- Ứng dụng mô hình Attention hoặc Transformer để tăng khả năng dự đoán
- Tích hợp dữ liệu từ các chỉ số vĩ mô (lãi suất, CPI, tỉ giá, giá dầu…)
- Triển khai lên nền tảng web hoặc mobile, phục vụ đầu tư thực tế

CHƯƠNG 2: CÁC KĨ THUẬT SỬ DỤNG

2.1. Phương pháp thu thập và xử lý dữ liệu

2.1.1. Nguồn dữ liệu

Dữ liệu được sử dụng trong đề tài được thu thập từ các nguồn tài chính uy tín như Yahoo Finance, Investing.com hoặc Vietstock.vn. Dữ liệu tập trung vào mã cổ phiếu VCB (Ngân hàng TMCP Ngoại thương Việt Nam), một trong những cổ phiếu bluechip có thanh khoản cao và ảnh hưởng lớn đến chỉ số VN-Index.

Thời gian thu thập dữ liệu kéo dài từ ngày 01/01/2020 đến ngày 29/05/2025, với tần suất theo ngày giao dịch. Đây là khoảng thời gian đủ dài để mô hình học được các xu hướng biến động ngắn hạn, trung hạn cũng như chu kỳ thị trường.

Dữ liệu gốc bao gồm các cột sau:

- **Date**: Ngày giao dịch
- **Open**: Giá mở cửa trong ngày
- **High**: Giá cao nhất trong phiên
- **Low**: Giá thấp nhất trong phiên
- **Close**: Giá đóng cửa (biến mục tiêu cần dự báo)
- **Volume**: Khối lượng giao dịch trong phiên

2.1.2. Tiền xử lý dữ liệu

Sau khi thu thập dữ liệu, quá trình tiền xử lý được thực hiện nhằm đảm bảo dữ liệu đầu vào chất lượng cao, bao gồm:

- **Lọc bỏ giá trị thiếu (missing values)** và dữ liệu trùng lặp
- **Chuyển đổi kiểu dữ liệu** của cột ngày giao dịch về dạng datetime
- **Sắp xếp lại dữ liệu theo thời gian tăng dần** để đảm bảo tính liên tục của chuỗi
- **Chuẩn hóa dữ liệu** bằng phương pháp Min-Max Scaling về khoảng [0, 1] để phù hợp với yêu cầu của các mô hình học sâu như LSTM
- **Tạo thêm các đặc trưng kỹ thuật** (technical indicators) để tăng tính biểu đạt của dữ liệu:

- Return_1d: Lợi suất một ngày, giúp mô hình nhận diện biến động ngắn hạn
- MA_5, MA_20: Trung bình động 5 và 20 ngày, phản ánh xu hướng giá ngắn và trung hạn
- Volume_MA_10: Trung bình động khối lượng giao dịch 10 phiên

Sau khi xử lý, dữ liệu được chia thành hai phần:

- **Tập huấn luyện**: 80% đầu chuỗi thời gian
- **Tập kiểm tra**: 20% còn lại

Việc chia theo thời gian đảm bảo không vi phạm tính chất chuỗi thời gian, tránh hiện tượng thông tin từ tương lai bị rò rỉ vào mô hình.

```
# Check missing

print("\n=== SỐ LƯỢNG NULL ===")

print(df.isnull().sum())
```

```
# Fill missing (nếu có): dùng median cho numeric

for col in df.select_dtypes(include='number').columns:

    if df[col].isnull().any():

        df[col].fillna(df[col].median(), inplace=True)
```

```
# Check outliers với IQR và cap giá trị ngoài biên

def cap_outliers(series):

    Q1 = series.quantile(0.25)

    Q3 = series.quantile(0.75)

    IQR = Q3 - Q1

    lower = Q1 - 1.5 * IQR

    upper = Q3 + 1.5 * IQR

    return series.clip(lower, upper)



numeric_cols = df.select_dtypes(include='number').columns

for col in numeric_cols:

    df[col] = cap_outliers(df[col])
```

2.1.3. Phân tích dữ liệu khám phá (EDA)

Sau khi hoàn thiện các bước tiền xử lý, em tiến hành phân tích dữ liệu khám phá (Exploratory Data Analysis – EDA) để hiểu rõ hơn về đặc điểm của dữ liệu và mối quan hệ giữa các biến số. Các biểu đồ đường (line plot) được sử dụng để quan sát xu hướng giá đóng cửa theo thời gian, biểu đồ phân phối (histogram, kdeplot) giúp nhận diện đặc điểm phân phối của giá cổ phiếu và lợi suất, trong khi biểu đồ hộp (boxplot) hỗ trợ phát hiện các giá trị ngoại lệ.

Em cũng sử dụng ma trận tương quan (correlation heatmap) để đánh giá mức độ liên quan giữa các biến đầu vào với biến mục tiêu (giá đóng cửa). Việc này giúp lựa chọn các đặc trưng phù hợp, loại bỏ các biến không có ý nghĩa hoặc gây nhiễu cho mô hình. Ngoài ra, các biểu đồ scatter plot giữa các đặc trưng kỹ thuật (MA_5, MA_20, Return_1d) với giá đóng cửa cũng được sử dụng để kiểm tra trực quan mối quan hệ tuyến tính hoặc phi tuyến giữa các biến.

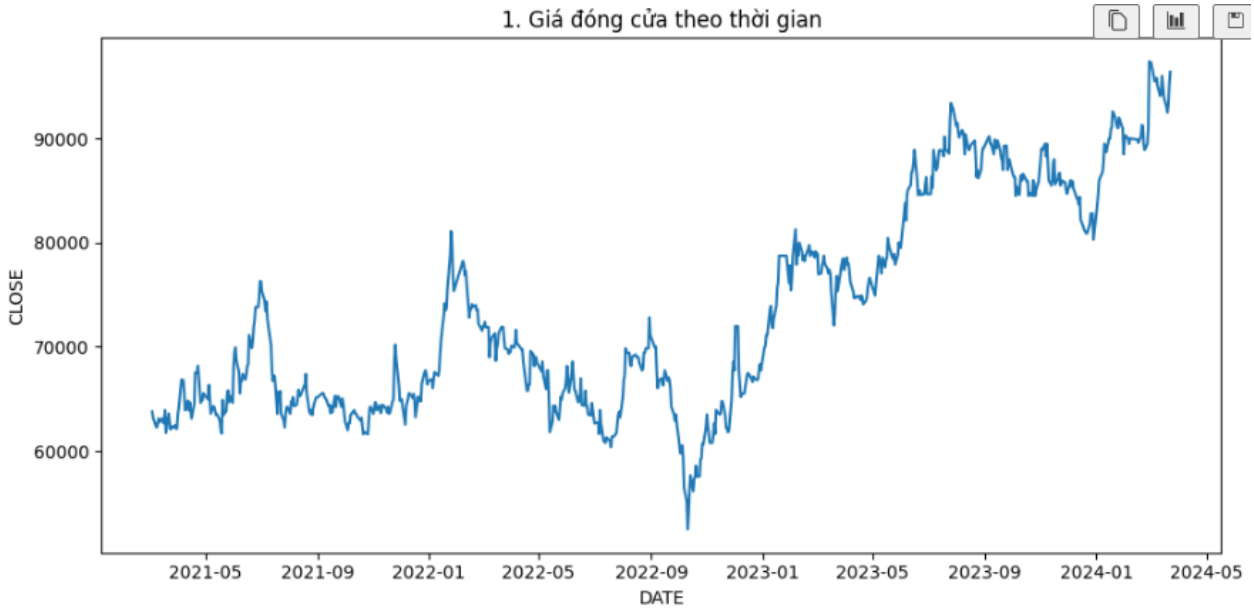

Hình 2.1. Giá đóng cửa theo thời gian

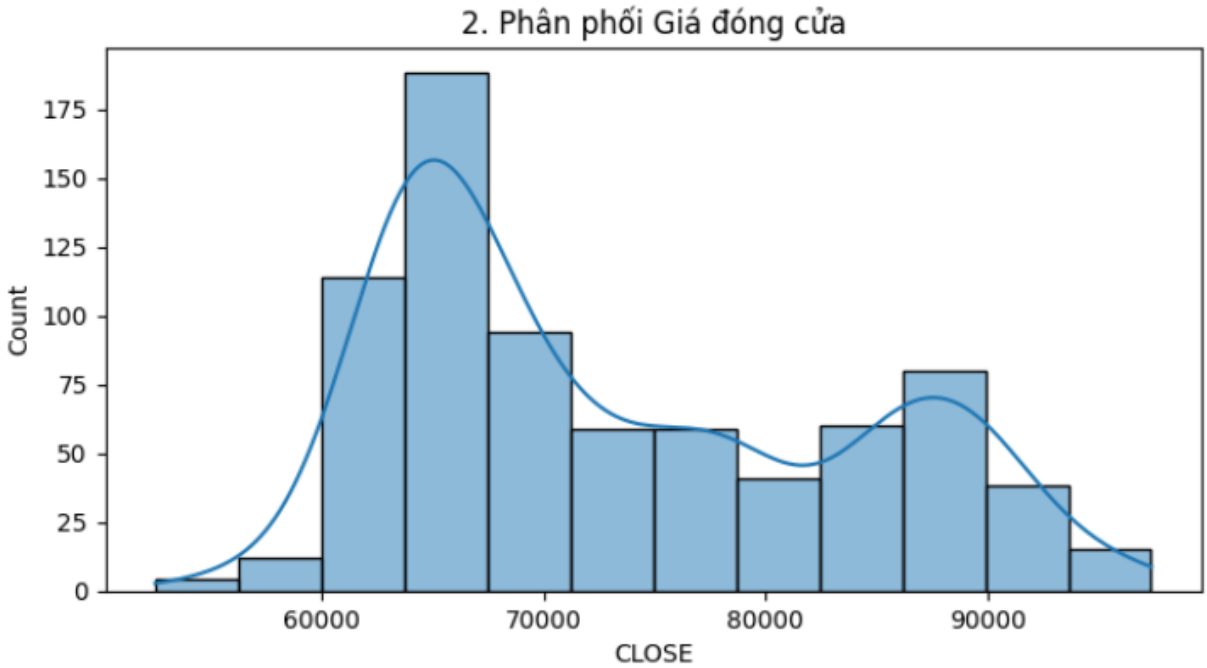

Hình 2.2. Phân phối giá đóng cửa

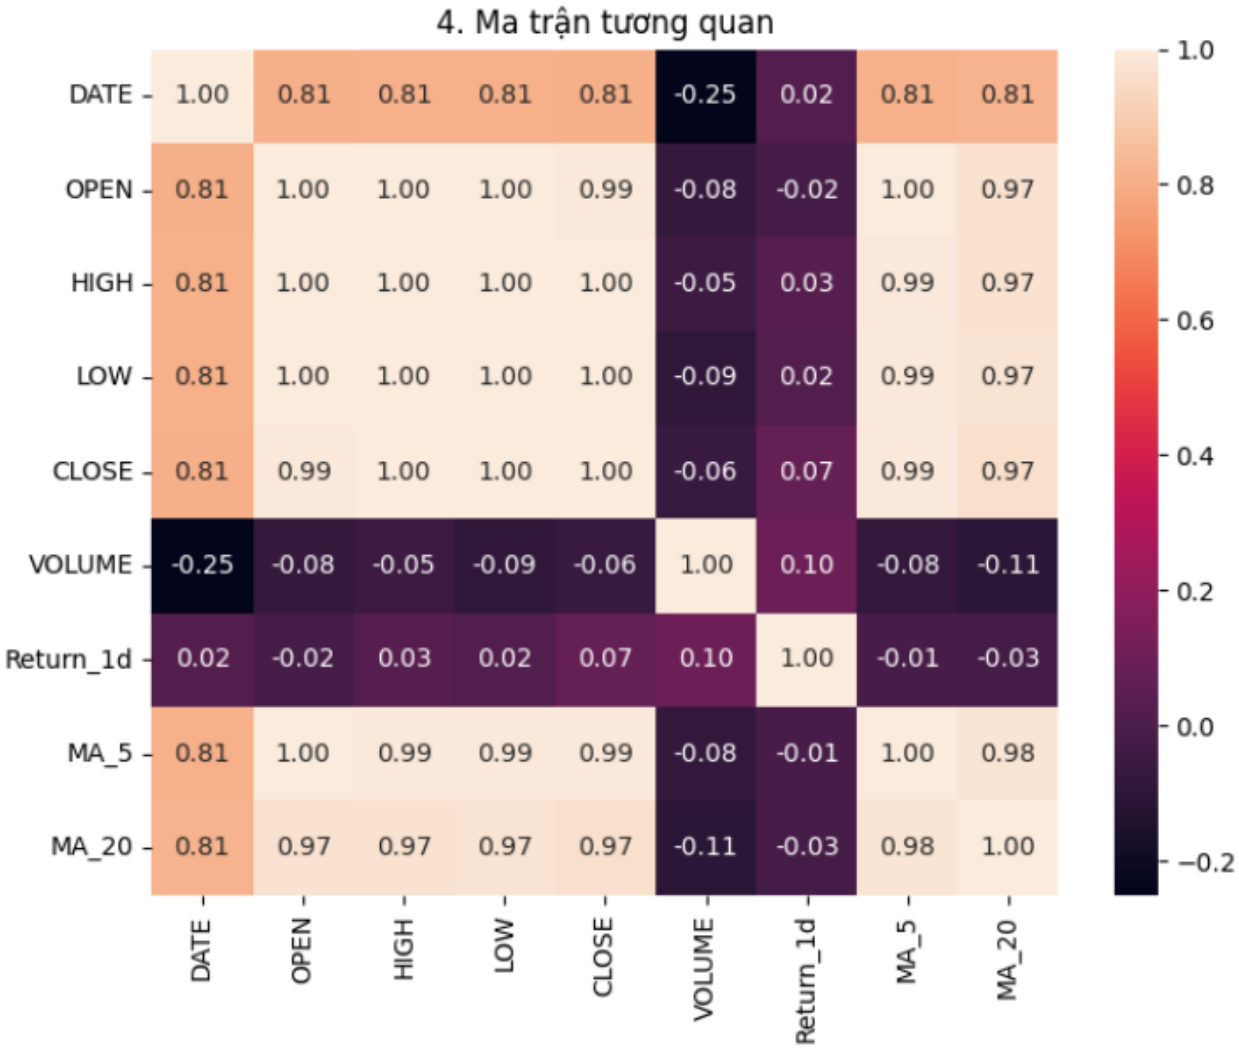

Hình 2.3. Ma trận tương quan

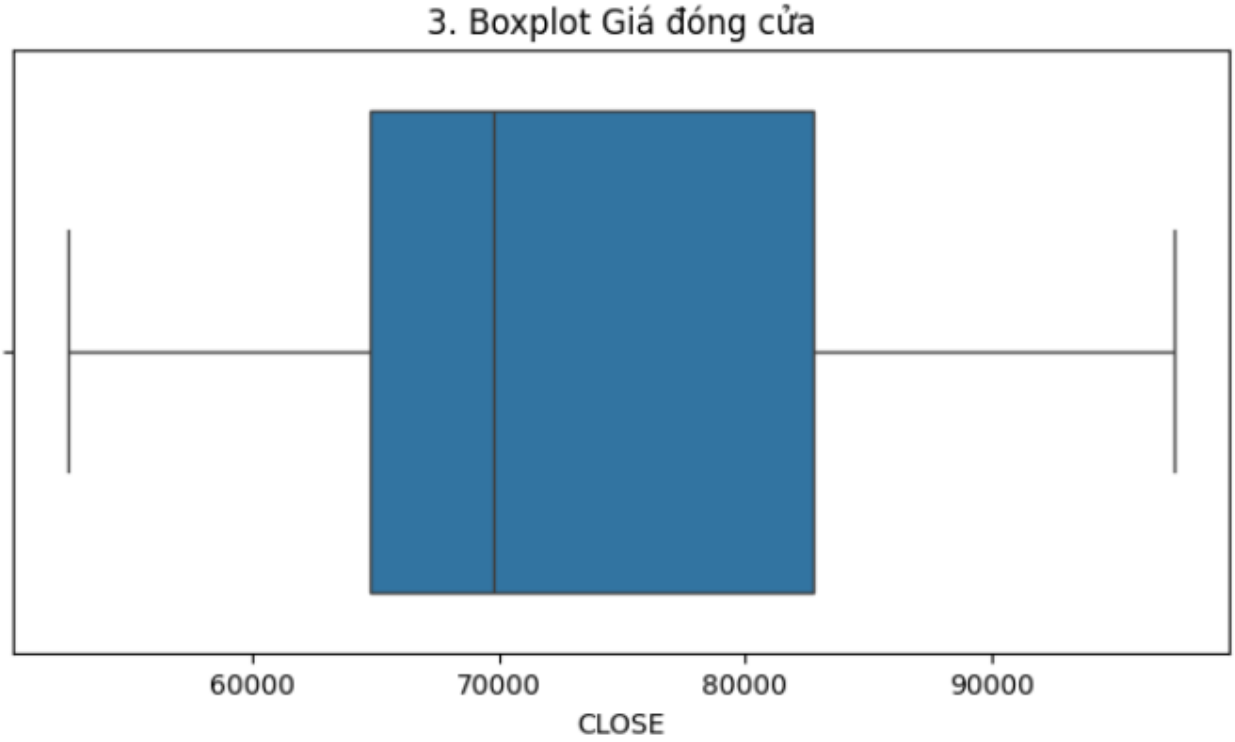
3. Boxplot Giá đóng cửa
60000
70000
80000
90000
CLOSE

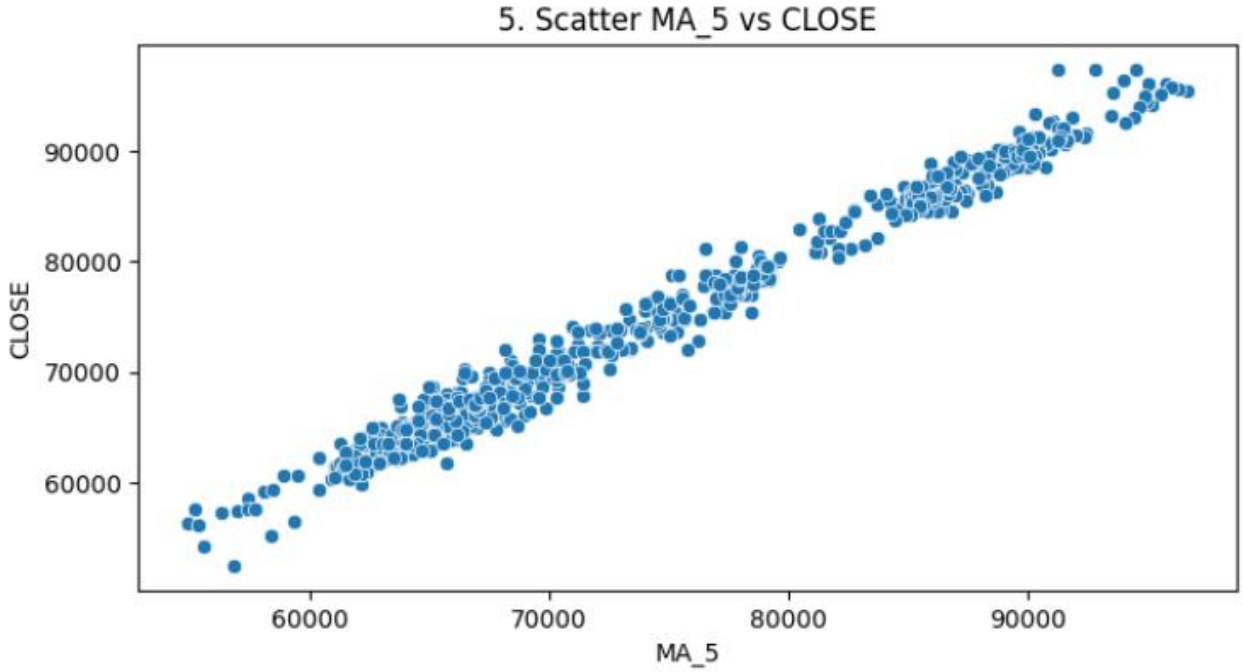
5. Scatter MA_5 vs CLOSE
90000
80000
70000
60000
CLOSE
60000
70000
80000
90000
MA_5

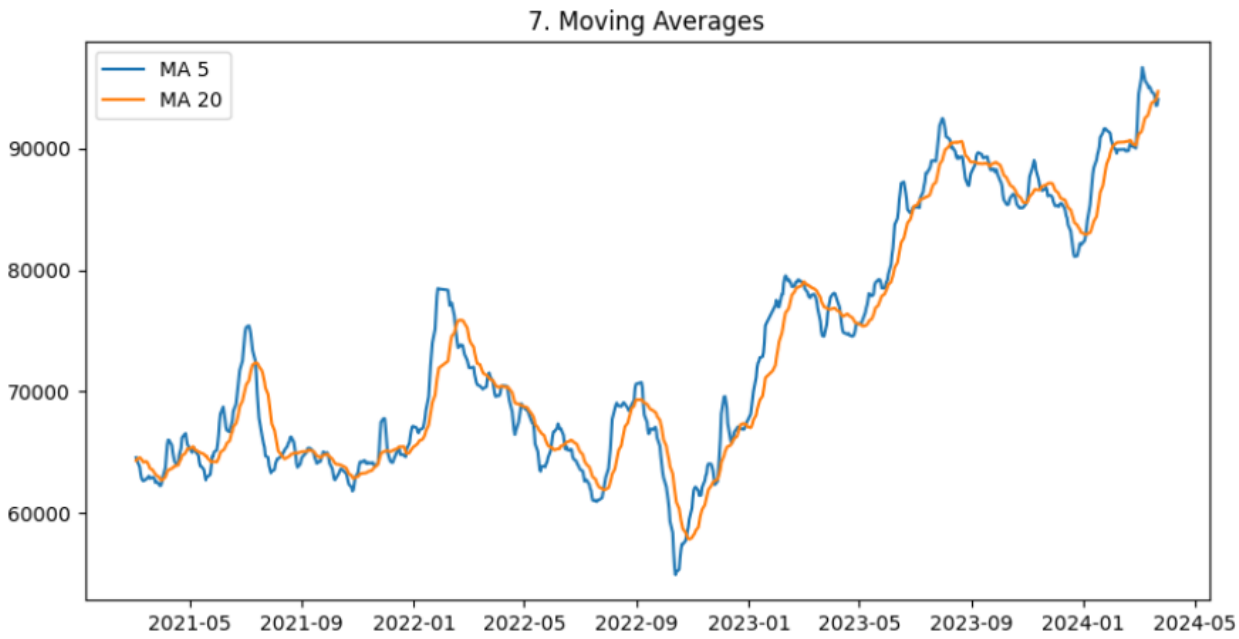

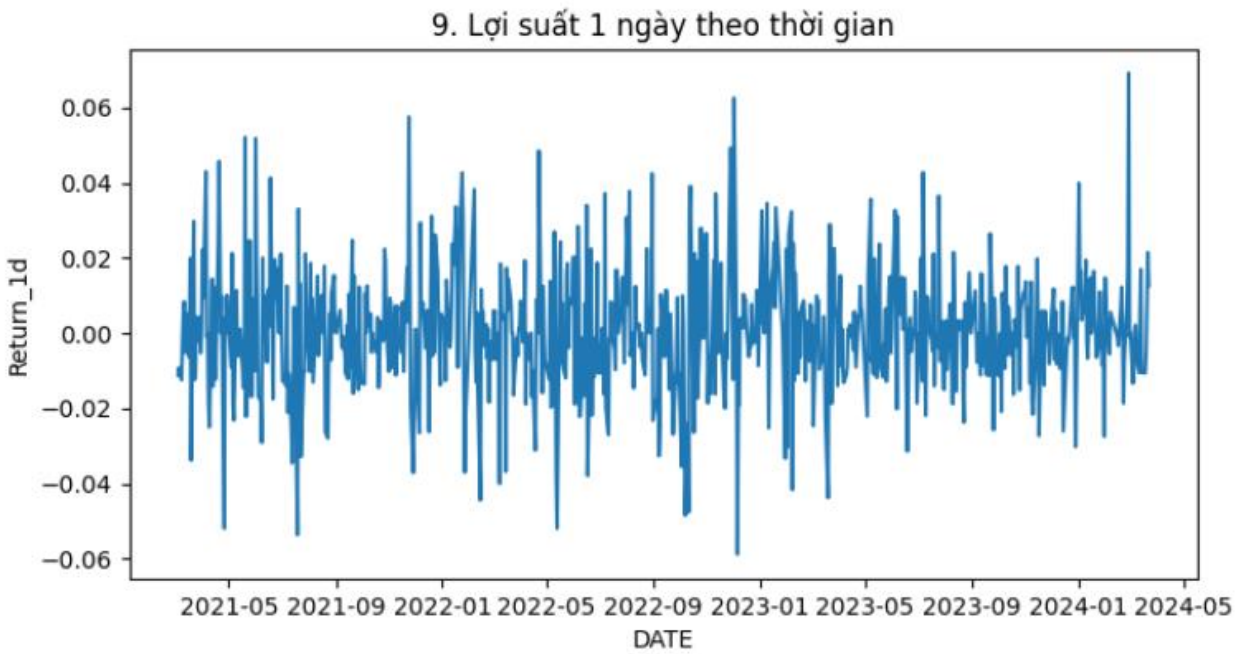

2.2. Mô hình trí tuệ nhân tạo áp dụng

2.2.1. Linear Regression

2.2.1.1. Khái niệm

Linear Regression là một trong những thuật toán cơ bản và phổ biến nhất trong học máy, thuộc nhóm **hồi quy có giám sát (supervised regression)**.

Mục tiêu của Linear Regression là tìm ra mối quan hệ tuyến tính giữa biến đầu vào (đặc trưng) và biến đầu ra (mục tiêu).

Trong bài toán dự báo giá cổ phiếu, Linear Regression sẽ học mối quan hệ giữa các yếu tố như MA5, MA20, Volume, Return,… với giá đóng cửa (Close) để dự đoán giá tương lai.

2.2.1.2. Công thức toán học

Trường hợp đơn biến (Simple Linear Regression):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$

Trong đó:

- y: biến mục tiêu (giá cần dự báo)
- x: biến đầu vào (ví dụ: MA_5)
- β0: hệ số chệch (intercept)
- β1: hệ số hồi quy (slope)
- ε: sai số (residual)

Trường hợp đa biến (Multiple Linear Regression):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \varepsilon$$

Trong đó:

- $x_1, x_{2,\ldots}, x_n$: các đặc trưng (features) như Volume, MA_5, MA_20,...
- β1,...,βn: hệ số tương ứng mà mô hình học được

2.2.1.3. Mục tiêu của mô hình

- Tối thiểu hóa sai số giữa giá trị thực yyy và giá trị dự đoán $\hat{y}$
- Dùng phương pháp **Bình phương tối thiểu (OLS)**:

$$\text{Minimize} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

2.2.1.4. Ưu điểm và nhược điểm

Ưu điểm	**Nhược điểm**
Dễ hiểu, dễ triển khai	Giả định tuyến tính nên khó áp dụng với dữ liệu phi tuyến
Huấn luyện nhanh, hiệu quả với dữ liệu ít nhiễu	Nhạy cảm với outliers (giá trị ngoại lệ)
Dễ giải thích, trực quan hóa kết quả	Không tự động học tương tác phức tạp giữa các biến

2.2.1.5. Ứng dụng trong dự báo giá cổ phiếu

- Khi dữ liệu biến động ổn định và có xu hướng tuyến tính (ví dụ: VCB trong 3 năm gần đây), Linear Regression **vẫn có thể cho kết quả rất tốt**.
- Có thể kết hợp Linear Regression với **phân tích kỹ thuật** như MA (moving average), Return, khối lượng giao dịch để cải thiện độ chính xác.
- Thường dùng làm **mô hình baseline** để so sánh với các mô hình phức tạp hơn như Random Forest, Gradient Boosting hoặc LSTM.

2.2.2. Random Forest Regressor

Là mô hình học máy thuộc nhóm ensemble, sử dụng nhiều cây quyết định huấn luyện song song để cải thiện độ chính xác và giảm overfitting. Random Forest hoạt động tốt với dữ liệu nhiễu và có khả năng học quan hệ phi tuyến giữa các biến.

- Ưu điểm: Ổn định, không yêu cầu chuẩn hóa dữ liệu, học tốt các mối quan hệ phi tuyến.
- Nhược điểm: Khó giải thích, thời gian huấn luyện tăng theo số lượng cây.

2.2.3. Gradient Boosting Regressor (GBoost)

Khái niệm tổng quan

Gradient Boosting là một thuật toán học máy thuộc nhóm "ensemble learning" – học tổ hợp. Cụ thể, đây là một kỹ thuật **boosting**, tức là kết hợp nhiều mô hình yếu (weak learners) lại với nhau để tạo thành một mô hình mạnh (strong learner). Mỗi mô hình yếu thường là một **cây quyết định (decision tree)** nông (shallow tree).

Gradient Boosting được gọi là "gradient" vì tại mỗi bước lặp, nó tối ưu hóa mô hình bằng cách **cộng thêm một cây mới theo hướng đạo hàm âm của hàm mất mát (loss function)** – chính là gradient. Nhờ đó, mô hình được cập nhật dần dần để giảm lỗi một cách hiệu quả.

Khác với **Random Forest** (học song song), Gradient Boosting học **tuần tự**, và mỗi mô hình con mới được huấn luyện để **sửa lỗi của tổng các mô hình trước đó**.

Cơ chế hoạt động

Giả sử ta có hàm dự báo tổng quát sau M vòng lặp:

$$F_M(x) = F_0(x) + \sum_{m=1}^{M} \gamma_m h_m(x)$$

$F_0(x)$: mô hình khởi tạo (thường là trung bình của giá trị mục tiêu y)

- $h_{m(x)}$: mô hình yếu (cây quyết định) ở vòng lặp thứ m
- γ_m: hệ số học (learning rate)

Tại mỗi vòng boosting, các bước như sau:

2.2.3.1. Tính sai số (residual) hoặc đạo hàm của hàm mất mát:

$$r_{im} = -\left[\frac{\partial L\big(y_i, F(x_i)\big)}{\partial F(x_i)}\right] F = F_m - 1$$

2.2.3.2.Huấn luyện mô hình yếu $h_{m(x)}$ để dự đoán r_{im}.

Tính hệ số γ_m sao cho hàm mất mát tổng được tối ưu:

$$\gamma_m = \arg\min \sum_i \mathrm{L}(\mathrm{y_i}, \mathrm{F_{m-1}}(\mathrm{x_i}) + \gamma h_m(\mathrm{x_i}))$$

Cập nhật mô hình tổng:

$$F_M(x) = F_{m-1}(x) + \gamma_m h_m(x)$$

Hàm mất mát thường dùng

- **Hồi quy (Regression):** $\boldsymbol{L(y, \hat{y}) = (y - \hat{y})^2}$ (Mean Squared Error)
- **Phân loại (Classification):** $L(y, \hat{y}) = -log(\hat{y}) - (1 - y)\, log(1 - \hat{y})$ (Cross-entropy)

Các biến thể phổ biến

Thuật toán	**Mô tả ngắn**
XGBoost	Tối ưu hóa Gradient Boosting bằng Regularization và tính song song hóa cao
LightGBM	Dành cho dữ liệu lớn, chia nhánh theo histogram và leaf-wise growth
CatBoost	Hỗ trợ tốt cho dữ liệu phân loại, xử lý trực tiếp categorical features

Ưu điểm và nhược điểm

Ưu điểm:

- Hiệu quả cao trên nhiều loại dữ liệu
- Giảm bias và variance tốt hơn cây đơn

- Khả năng biểu diễn tốt các mối quan hệ phi tuyến

Nhược điểm:

- Dễ overfit nếu không điều chỉnh tham số đúng
- Cần nhiều thời gian huấn luyện hơn Random Forest
- Nhạy cảm với dữ liệu nhiễu hoặc outliers

Ứng dụng trong bài toán dự báo giá cổ phiếu

Gradient Boosting rất phù hợp cho bài toán tài chính – nơi dữ liệu nhiều nhiễu, phi tuyến, và không ổn định. Với khả năng học tốt các đặc trưng kỹ thuật như MA, Return, Volume…, Gradient Boosting giúp dự báo xu hướng giá cổ phiếu chính xác hơn các mô hình tuyến tính đơn giản.

Trong đồ án này, Gradient Boosting được lựa chọn là **mô hình chính** vì cân bằng tốt giữa độ chính xác và tốc độ, đồng thời dễ triển khai, tinh chỉnh trên dữ liệu thực tế.

2.2.4. LSTM (Long Short-Term Memory)

Mạng LSTM (Long Short-Term Memory) là một biến thể đặc biệt của mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN), được thiết kế để xử lý và dự đoán dữ liệu tuần tự có độ dài lớn, chẳng hạn như chuỗi thời gian. Điểm mạnh của LSTM là khả năng ghi nhớ thông tin lâu dài nhờ vào cấu trúc đặc biệt gồm các cổng điều khiển.

Cấu trúc của tế bào LSTM

Mỗi tế bào LSTM bao gồm ba cổng chính:

- **Cổng quên (Forget Gate)**: quyết định thông tin nào trong trạng thái bộ nhớ cũ sẽ bị loại bỏ.
- **Cổng đầu vào (Input Gate)**: xác định thông tin mới nào sẽ được thêm vào trạng thái bộ nhớ.
- **Cổng đầu ra (Output Gate)**: kiểm soát thông tin nào từ trạng thái bộ nhớ sẽ được xuất ra làm đầu ra.

Cấu trúc này cho phép LSTM có khả năng "ghi nhớ chọn lọc" và "quên chọn lọc", giúp học được mối quan hệ dài hạn trong chuỗi dữ liệu.

Sơ đồ tế bào LSTM

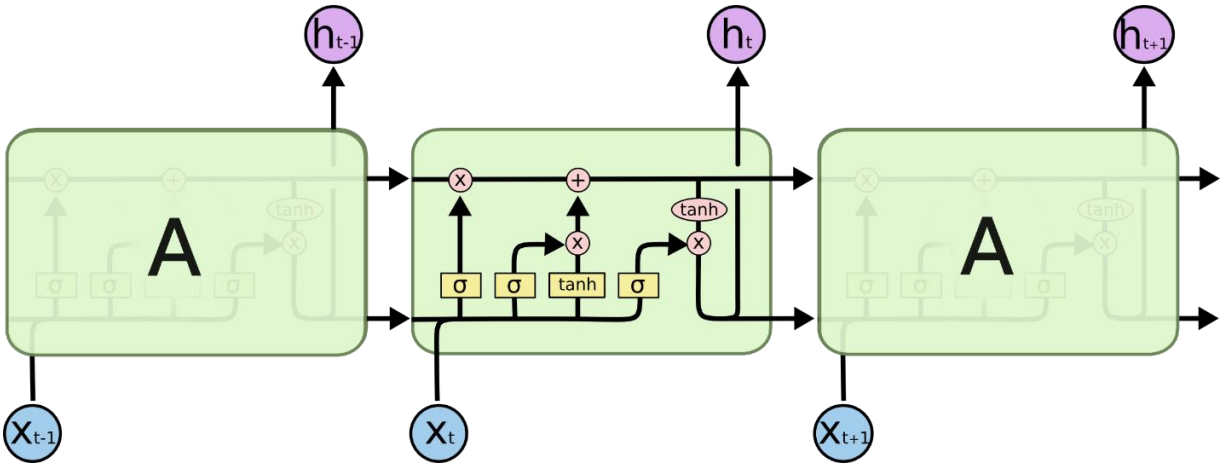

Hình 2.4: Cấu trúc tế bào LSTM (nguồn: Chris Olah, 2015)

Công thức hoạt động của LSTM

Tại thời điểm t, với đầu vào x_t, trạng thái ẩn trước đó h_{t-1} và trạng thái bộ nhớ C_{t-1}, các bước hoạt động của LSTM được mô tả như sau:

- **Cổng quên**:

$$f_t = \sigma(W_f \,.\, [h_{t-1}, x_t] + b_f\,)$$

- **Cổng đầu vào**:

$$i_t = \sigma(W_f \,.\, [h_{t-1}, x_t] + b_f\,)$$
$$\tilde{C}_t = \tanh\,(W_C \,.\, [h_{t-1}, x_t] + b_C)$$

Cập nhật trạng thái bộ nhớ:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

- **Cổng đầu ra**:

$$o_t = \sigma(W_o \,.\, [h_{t-1}, x_t] + b_o\,)$$
$$h_t = o_t * \tanh\,(C_t)$$

Trong đó:

- σ: hàm sigmoid
- tanh: hàm tanh
- W, b trọng số và độ lệch
- $*$: phép nhân từng phần tử

Ứng dụng của LSTM trong dự báo giá cổ phiếu

LSTM phù hợp với các bài toán dự báo chuỗi thời gian như giá cổ phiếu, vì nó có thể ghi nhớ xu hướng trong quá khứ và dự đoán giá tương lai. Nhờ cấu trúc đặc biệt, LSTM cho kết quả ổn định và chính xác hơn các mô hình truyền thống trong các bài toán có tính tuần tự dài hạn.

2.3. Tiêu chí đánh giá mô hình

Để đánh giá hiệu quả dự báo của các mô hình, em sử dụng các chỉ số phổ biến trong bài toán hồi quy, bao gồm:

R2 Score (Hệ số xác định): Chỉ số này cho biết tỷ lệ phương sai của biến mục tiêu (giá đóng cửa cổ phiếu) được giải thích bởi các đặc trưng đầu vào. Giá trị R2 càng gần 1 chứng tỏ mô hình dự báo càng tốt.

RMSE (Root Mean Squared Error – Sai số bình phương trung bình căn bậc hai): Đo lường mức độ sai lệch trung bình giữa giá trị dự báo và giá trị thực tế. RMSE càng nhỏ, mô hình càng chính xác.

MAE (Mean Absolute Error – Sai số tuyệt đối trung bình): Đánh giá mức độ sai lệch tuyệt đối trung bình giữa giá trị dự báo và thực tế, giúp nhận diện các sai số lớn bất thường.

MSE (Mean Squared Error – Sai số bình phương trung bình): Đo lường tổng thể mức độ sai lệch, nhấn mạnh các sai số lớn.

Ngoài ra, em còn sử dụng các biểu đồ trực quan như biểu đồ đường so sánh giá dự báo và giá thực tế, biểu đồ phân phối sai số để đánh giá trực quan hiệu quả của từng mô hình.

CHƯƠNG 3: TRIỂN KHAI HỆ THỐNG VÀ GIAO DIỆN NGƯỜI DÙNG

3.1. Môi trường thực nghiệm

3.1.1 Cấu hình

Ngôn ngữ: Python 3.12.6

IDE: Jupyter Notebook

Thư viện sử dụng: pandas, numpy, sklearn, tensorflow, matplotlib, seaborn, v.v.

Framework: TensorFlow / Keras

Cấu hình máy: CPU Intel Core i5, RAM 8GB (không dùng GPU)

3.1.2. Dữ liệu sử dụng

Dữ liệu sử dụng là lịch sử giao dịch cổ phiếu **VCB (Vietcombank)** được thu thập từ Kaglee, với khoảng thời gian từ **04/01/2021 đến 22/03/2024**, gồm hơn 803 phiên giao dịch.

Mỗi dòng trong dữ liệu chứa các trường:

- Date: ngày giao dịch
- Open, High, Low, Close: các mức giá
- Volume: khối lượng giao dịch

```python
print("\n=== CÁC CỘT TRONG DỮ LIỆU ===")
print(df.columns.tolist())

print("\nĐộ dài của tập dữ liệu:", len(df))

# shape
print("\n=== KÍCH THƯỚC CỦA TẬP DỮ LIỆU ===")
print("Số hàng:", df.shape[0])
print("Số cột:", df.shape[1])
```

[8] Python

```
=== CÁC CỘT TRONG DỮ LIỆU ===
['DATE', 'OPEN', 'HIGH', 'LOW', 'CLOSE', 'VOLUME']

Độ dài của tập dữ liệu: 802

=== KÍCH THƯỚC CỦA TẬP DỮ LIỆU ===
Số hàng: 802
Số cột: 6
```

Ngoài ra, trong quá trình tiền xử lý, các đặc trưng kỹ thuật được bổ sung:

- **Return_1d**: lợi suất 1 ngày
- **MA_5**, **MA_20**: trung bình động 5 và 20 ngày
- **Volume_MA_10**: trung bình động khối lượng

Toàn bộ dữ liệu được chuẩn hóa bằng MinMaxScaler trước khi đưa vào mô hình LSTM và Gradient Boosting.

TIỀN XỬ LÝ DỮ LIỆU

```python
# Check missing
print("\n=== SỐ LƯỢNG NULL ===")
print(df.isnull().sum())
```

✓ 0.0s

```
=== SỐ LƯỢNG NULL ===
DATE      0
OPEN      0
HIGH      0
LOW       0
CLOSE     0
VOLUME    0
dtype: int64
```

Thêm các feature kĩ thuật:

```python
# Thêm các feature kỹ thuật
df.sort_values('DATE', inplace=True)
df['Return_1d'] = df['CLOSE'].pct_change()
df['MA_5'] = df['CLOSE'].rolling(5).mean()
df['MA_20'] = df['CLOSE'].rolling(20).mean()
df.dropna(inplace=True)
df
```

[10] ✓ 0.0s Python

	DATE	OPEN	HIGH	LOW	CLOSE	VOLUME	Return_1d	MA_5	MA_20
782	2021-01-29	56048.48	63521.61	56048.48	60965.01	1359000.0	0.026490	63508.498	66501.0275
781	2021-02-01	62931.62	62931.62	59653.93	59719.49	1331300.0	-0.020430	62013.872	66242.0900
780	2021-02-02	60309.47	63390.50	60309.47	63259.39	1152800.0	0.059275	61436.998	66150.3145
779	2021-02-03	64177.14	64898.24	63324.95	64832.68	1454600.0	0.024870	61633.658	65950.3755
778	2021-02-04	64832.68	64898.24	61554.99	64832.68	967300.0	0.000000	62721.850	65684.8825
...	...	...	...	...	...	...	...	...	...
4	2024-03-18	94300.00	94500.00	92500.00	93000.00	1839300.0	-0.010638	94480.000	93900.0000
3	2024-03-19	92500.00	93500.00	92500.00	92500.00	868500.0	-0.005376	94100.000	93960.0000
2	2024-03-20	92500.00	94100.00	92500.00	93200.00	897700.0	0.007568	93540.000	94060.0000
1	2024-03-21	94000.00	95500.00	94000.00	95200.00	1452700.0	0.021459	93580.000	94345.0000
0	2024-03-22	95200.00	96800.00	95200.00	96400.00	1844100.0	0.012605	94060.000	94720.0000

Scale dữ liệu

```python
# 4. Scale dữ liệu
scaler = MinMaxScaler(feature_range=(0,1))
scaled_data = scaler.fit_transform(dataset)
```

3.1.3. Cài đặt mô hình và huấn luyện

Trong khuôn khổ đồ án, đã triển khai và đánh giá bốn mô hình dự báo phổ biến trong lĩnh vực học máy và học sâu. Các mô hình này được lựa chọn nhằm đại diện cho ba hướng tiếp cận chính: hồi quy tuyến tính, mô hình ensemble (tổ hợp cây quyết định), và mạng nơ-ron hồi tiếp. Cụ thể như sau:

Linear Regression

Linear Regression là mô hình cơ bản nhất trong bài toán hồi quy. Mô hình này giả định mối quan hệ tuyến tính giữa các biến đầu vào và biến mục tiêu (giá cổ phiếu đóng cửa).
Mặc dù đơn giản, Linear Regression thường được sử dụng như một mô hình chuẩn tham chiếu (baseline) để so sánh với các mô hình phức tạp hơn.

- Ưu điểm: Dễ huấn luyện, nhanh, dễ diễn giải.
- Hạn chế: Không xử lý được mối quan hệ phi tuyến, không khai thác được tính chuỗi trong dữ liệu.

Random Forest Regressor

Random Forest là mô hình tổ hợp gồm nhiều cây quyết định, mỗi cây được huấn luyện trên một tập con ngẫu nhiên của dữ liệu. Kết quả cuối cùng là trung bình dự báo của tất cả các cây.

- Ưu điểm: Học tốt các mối quan hệ phi tuyến, ổn định với dữ liệu nhiễu, ít overfitting.
- Hạn chế: Khó giải thích, không khai thác tốt chuỗi thời gian nếu không trích xuất đặc trưng phù hợp.

Gradient Boosting Regressor (GBoost)

Gradient Boosting là mô hình tăng cường, hoạt động bằng cách xây dựng các cây kế tiếp nhau, trong đó mỗi cây học từ sai số còn lại của các cây trước. Trong đồ án, em sử dụng XGBoost làm đại diện cho kỹ thuật này.

- Ưu điểm: Độ chính xác cao, học tốt các mối quan hệ phi tuyến, có thể tinh chỉnh sâu bằng các tham số.
- Hạn chế: Thời gian huấn luyện lâu hơn so với Random Forest, dễ bị overfit nếu tham số chưa tối ưu.

Với tính ổn định, linh hoạt và hiệu quả cao, Gradient Boosting được lựa chọn làm mô hình chính trong đồ án.

LSTM (Long Short-Term Memory)

LSTM là một kiến trúc đặc biệt của mạng nơ-ron hồi tiếp (RNN), được thiết kế để ghi nhớ thông tin trong chuỗi thời gian dài. LSTM phù hợp với các bài toán như dự báo giá cổ phiếu, vốn mang tính chuỗi và có độ trễ thông tin.

Trong đồ án, mô hình LSTM được xây dựng với:

- Hai lớp LSTM (50 units), kèm Dropout 20% để giảm overfitting
- Cửa sổ thời gian: 60 ngày
- Đầu vào được chuẩn hóa và reshape về định dạng [samples, time_steps, 1]
- Ưu điểm: Ghi nhớ dài hạn, học được các mẫu phức tạp trong chuỗi.
- Hạn chế: Cần nhiều dữ liệu, dễ underfit nếu không tinh chỉnh kỹ. Độ nhạy cao với cách xử lý đầu vào.

Trong thực nghiệm, LSTM cho kết quả kém hơn so với kỳ vọng. Nguyên nhân có thể do dữ liệu chưa đủ đa dạng, số lượng đặc trưng kỹ thuật còn ít, và mô hình chưa được tối ưu sâu về tham số (epoch, batch_size, learning rate...).

Dữ liệu được chia theo tỷ lệ:

- **Train**: 80%
- **Test**: 20%

```
# 3. Lấy độ dài dữ liệu train (80%)
training_data_len = int(np.ceil( len(dataset) * .8 ))
```

Với LSTM, dữ liệu được xử lý theo **cửa sổ thời gian 60 ngày**, reshape lại về dạng [samples, time_steps, features].

Tổng kết mô hình triển khai

Mô hình	**Tuyến Tính**	**Học phi tuyến**	**Xử lý chuỗi thời gian**	**Độ chính xác (trên dữ liệu này)**
Linear Regression	✅	❌	❌	⭐⭐⭐⭐
Random Forest	❌	✅	❌	⭐⭐⭐
Gradient Boosting	❌	✅	❌	⭐⭐⭐⭐
LSTM	❌	✅	✅	⭐

Với các đặc trưng hiện tại và chất lượng dữ liệu có được, mô hình **Gradient Boosting** cho kết quả tổng thể tốt và ổn định nhất, đồng thời không yêu cầu xử lý chuỗi quá phức tạp như LSTM. Do đó, mô hình này được lựa chọn làm **mô hình chính trong đồ án**.

3.1.4. Kết quả mô hình

Bảng kết quả đánh giá trên tập test :

Bản 3.3. So sánh đặc điểm các mô hình học máy

```
=== SO SÁNH CÁC MÔ HÌNH ===
                        R2         RMSE          MAE           MSE
Model
Linear Regression  0.988989   378.089436   295.905475  1.429516e+05
Random Forest      0.875109  1273.346233   843.333782  1.621411e+06
Gradient Boosting  0.887580  1208.100609   798.851798  1.459507e+06
LSTM               0.751117  1800.430813  1428.499399  3.241551e+06
```

Kết luận sơ bộ:

- Linear Regression cho kết quả tốt bất ngờ do dữ liệu có xu hướng tuyến tính ổn định.
- **Gradient Boosting** tuy không bằng Linear nhưng có khả năng khai thác tốt phi tuyến, **ổn định hơn trong dữ báo ngắn hạn**.
- LSTM cho kết quả **thấp đáng kể**, có thể do thiếu đặc trưng, chưa đủ epoch hoặc chuỗi thời gian chưa được tối ưu.

3.1.5. Phân tích và lựa chọn mô hình chính

Dựa vào kết quả, **lựa chọn Gradient Boosting làm mô hình chính** cho bài toán vì các lý do:

- Tính linh hoạt, khả năng học tốt mối quan hệ phi tuyến
- Ít yêu cầu xử lý dữ liệu phức tạp như LSTM
- Độ chính xác cao, sai số RMSE ~1208, MAE ~799 là chấp nhận được với dữ liệu cổ phiếu

LSTM tuy hiện đại nhưng không phù hợp trong trường hợp này, cần cải tiến thêm mới có thể vượt được GBoost.

3.2. Thiết kế giao diện web dự báo

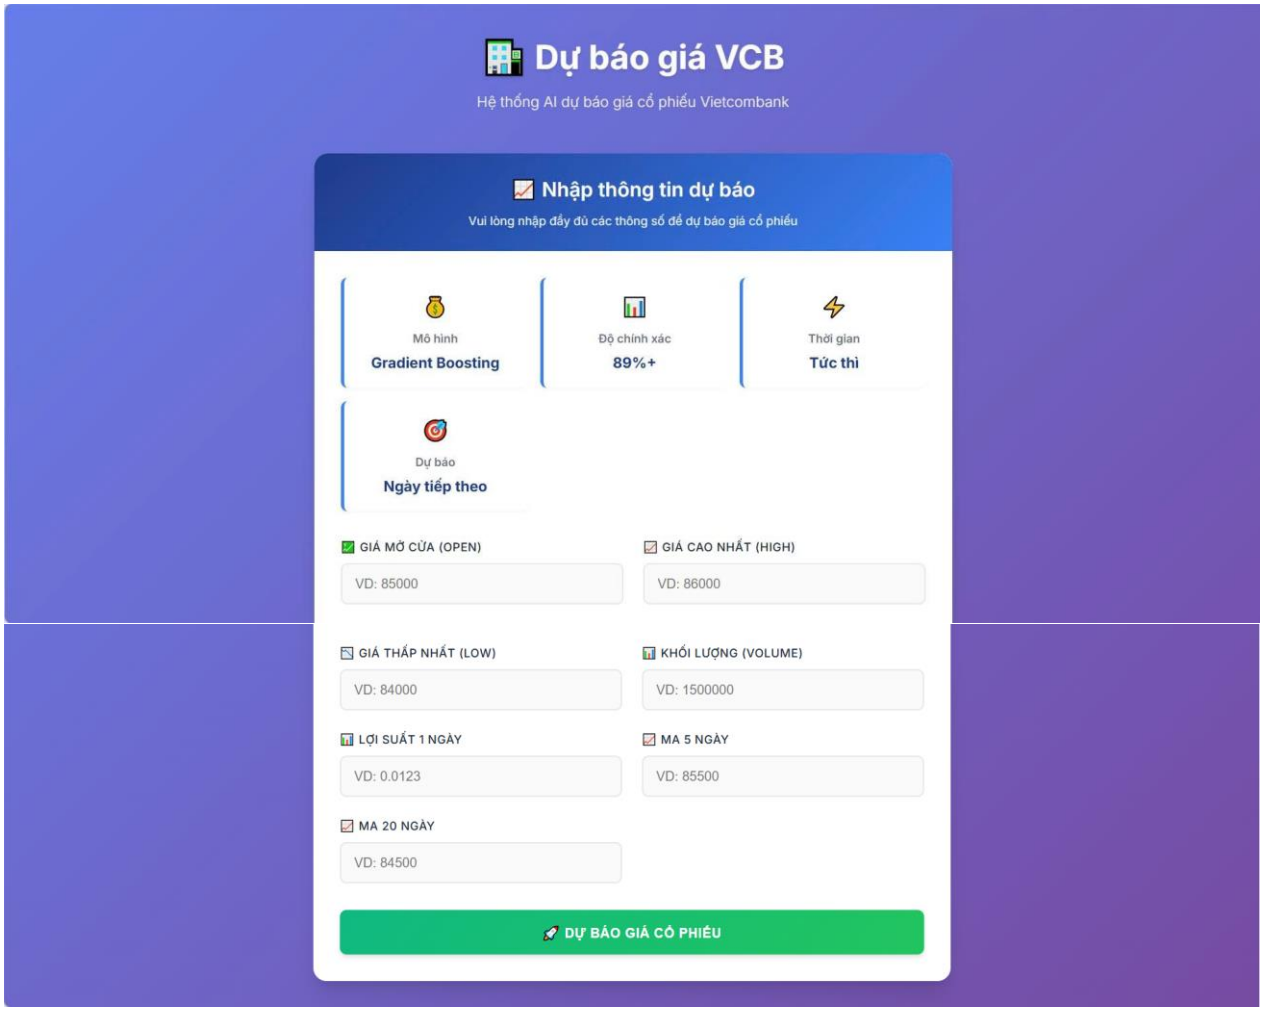

Giao diện web là cầu nối trực tiếp giữa hệ thống dự báo giá cổ phiếu ứng dụng trí tuệ nhân tạo với người dùng cuối. Một giao diện được thiết kế tốt không chỉ giúp người dùng dễ dàng thao tác, nhập liệu và nhận kết quả dự báo mà còn góp phần nâng cao trải nghiệm, tạo sự tin tưởng và chuyên nghiệp cho hệ thống. Trong khuôn khổ đồ án này, em đã chú trọng đầu tư vào khâu thiết kế giao diện web, đảm bảo các tiêu chí về thẩm mỹ, tính trực quan, thân thiện và tiện ích.

3.2.1. Nguyên tắc thiết kế giao diện

Ngay từ đầu, em xác định một số nguyên tắc quan trọng khi thiết kế giao diện web dự báo:

Đơn giản, dễ sử dụng: Giao diện cần tối giản, tránh rườm rà, tập trung vào chức năng chính là nhập dữ liệu và hiển thị kết quả dự báo. Người dùng chỉ cần vài thao tác cơ bản là có thể sử dụng hệ thống.

Trực quan, rõ ràng: Các trường nhập liệu, nút bấm, kết quả dự báo phải được bố trí hợp lý, dễ nhìn, dễ hiểu. Màu sắc, font chữ, kích thước các thành phần được lựa chọn hài hòa, tạo cảm giác thân thiện.

Phản hồi nhanh: Hệ thống cần cung cấp phản hồi ngay khi người dùng thao tác, ví dụ như hiển thị thông báo khi nhập thiếu dữ liệu, hiển thị trạng thái "đang dự báo" khi hệ thống xử lý, và trả về kết quả rõ ràng, dễ đọc.

Tương thích đa thiết bị: Giao diện được thiết kế responsive, đảm bảo hiển thị tốt trên cả máy tính, máy tính bảng và điện thoại di động.

3.2.2. Các thành phần chính của giao diện

Giao diện web dự báo giá cổ phiếu VCB được xây dựng với các thành phần chính như sau:

Tiêu đề và mô tả: Phần đầu trang hiển thị tên hệ thống ("Dự báo giá cổ phiếu VCB - AI Prediction") cùng mô tả ngắn gọn về chức năng, giúp người dùng hiểu rõ mục đích của ứng dụng.

Form nhập dữ liệu: Đây là khu vực quan trọng nhất, cho phép người dùng nhập các thông tin cần thiết để dự báo giá cổ phiếu, bao gồm: giá mở cửa (OPEN), giá cao nhất (HIGH), giá thấp nhất (LOW), khối lượng giao dịch (VOLUME), lợi suất 1 ngày (Return_1d), trung bình động 5 ngày (MA_5), trung bình động 20 ngày (MA_20). Các trường nhập liệu được bố trí dạng lưới (grid), có nhãn rõ ràng, hỗ trợ kiểm tra dữ liệu đầu vào.

Nút dự báo: Sau khi nhập đủ dữ liệu, người dùng nhấn nút "Dự báo" để gửi yêu cầu lên hệ thống. Nút này được thiết kế nổi bật, dễ nhận biết.

Kết quả dự báo: Kết quả dự báo giá đóng cửa cổ phiếu được hiển thị ngay bên dưới form nhập liệu, với định dạng nổi bật, dễ đọc. Ngoài ra, hệ thống còn có thể hiển thị các thông tin bổ sung như mức độ tin cậy, ghi chú hoặc biểu đồ so sánh với giá thực tế (nếu có).

Thông báo và trạng thái: Giao diện có các thông báo hướng dẫn, cảnh báo khi nhập thiếu hoặc sai dữ liệu, cũng như trạng thái "đang xử lý" khi hệ thống thực hiện dự báo.

3.2.3. Công nghệ và quá trình xây dựng giao diện

Giao diện web được xây dựng dựa trên nền tảng HTML5, CSS3 kết hợp với JavaScript để tăng tính tương tác. Em sử dụng các thư viện font chữ hiện đại (như Google Fonts), các biến CSS để dễ dàng tùy chỉnh màu sắc, kích thước, đồng thời áp dụng các hiệu ứng chuyển động nhẹ (animation) giúp giao diện sinh động hơn.

Để đảm bảo tính nhất quán và dễ bảo trì, em tổ chức mã nguồn giao diện theo cấu trúc rõ ràng, tách biệt phần style, script và nội dung HTML. Các thành phần được đặt tên có ý nghĩa, dễ hiểu, thuận tiện cho việc mở rộng hoặc chỉnh sửa sau này.

Giao diện được kiểm thử trên nhiều trình duyệt và thiết bị khác nhau để đảm bảo khả năng tương thích và trải nghiệm người dùng tốt nhất. Em cũng tham khảo ý kiến từ bạn bè, thầy cô để điều chỉnh giao diện phù hợp với thị hiếu và thói quen sử dụng của người Việt Nam.

3.2.4. Vai trò của giao diện trong hệ thống dự báo

Giao diện web không chỉ là nơi nhập và hiển thị dữ liệu mà còn đóng vai trò quan trọng trong việc xây dựng hình ảnh chuyên nghiệp cho hệ thống, tạo sự tin tưởng cho người dùng. Một giao diện đẹp, thân thiện sẽ giúp người dùng dễ dàng tiếp cận, sử dụng hệ thống thường xuyên hơn, từ đó phát huy tối đa giá trị của mô hình dự báo AI.

Ngoài ra, giao diện còn là nền tảng để tích hợp thêm các chức năng mở rộng trong tương lai như: hiển thị biểu đồ lịch sử giá, so sánh nhiều mã cổ phiếu, xuất báo cáo dự báo, hoặc kết nối với các hệ thống giao dịch thực tế.

Việc thiết kế giao diện web dự báo là một khâu quan trọng, góp phần quyết định sự thành công của hệ thống. Em đã đầu tư thời gian, công sức để xây dựng một giao diện hiện đại, trực quan, dễ sử dụng, đáp ứng tốt nhu cầu thực tiễn và tạo nền tảng vững chắc cho việc phát triển, mở rộng hệ thống trong tương lai.

3.3. Tích hợp mô hình AI vào ứng dụng Flask

Sau khi hoàn thiện việc huấn luyện và lựa chọn mô hình dự báo giá cổ phiếu tối ưu, bước tiếp theo là tích hợp mô hình AI vào ứng dụng web để phục vụ người dùng cuối. Trong đồ án này, em lựa chọn Flask – một framework web nhẹ, linh hoạt và phổ biến của Python – để xây dựng ứng dụng web dự báo giá cổ phiếu VCB. Việc tích hợp mô hình AI vào Flask không chỉ giúp tự động hóa quá trình dự báo mà còn tạo điều kiện thuận lợi cho việc mở rộng, bảo trì và phát triển hệ thống trong tương lai.

3.3.1. Chuẩn bị mô hình và môi trường tích hợp

Trước tiên, các mô hình học máy sau khi huấn luyện được lưu trữ dưới dạng file (thường là định dạng .pkl sử dụng thư viện joblib hoặc pickle). Việc lưu trữ này giúp tiết kiệm thời gian, không cần huấn luyện lại mô hình mỗi khi khởi động ứng dụng, đồng thời đảm bảo tính nhất quán giữa kết quả dự báo trên web và kết quả đã kiểm thử trước đó.

Môi trường tích hợp được chuẩn bị với các thư viện cần thiết như Flask, pandas, numpy, scikit-learn, joblib,… đảm bảo khả năng đọc dữ liệu, xử lý đầu vào và thực hiện dự báo một cách nhanh chóng, chính xác.

3.3.2. Xây dựng cấu trúc ứng dụng Flask

Ứng dụng Flask được tổ chức theo mô hình MVC (Model-View-Controller) đơn giản:

Model: Chính là mô hình AI đã được huấn luyện và lưu trữ. Khi ứng dụng khởi động, mô hình này sẽ được nạp vào bộ nhớ để sẵn sàng phục vụ các yêu cầu dự báo.

View: Là các template HTML (ví dụ: index.html) chịu trách nhiệm hiển thị giao diện người dùng, nhận dữ liệu đầu vào và trả về kết quả dự báo.

Controller: Là các hàm xử lý trong Flask (route functions), nhận dữ liệu từ người dùng, xử lý dữ liệu, gọi mô hình AI để dự báo và trả kết quả về giao diện.

3.3.3. Quy trình xử lý yêu cầu dự báo

Quy trình xử lý một yêu cầu dự báo trên ứng dụng Flask diễn ra như sau:

Người dùng nhập dữ liệu: Người dùng truy cập giao diện web, nhập các thông số cần thiết (giá mở cửa, giá cao nhất, giá thấp nhất, khối lượng giao dịch, các đặc trưng kỹ thuật…) vào form nhập liệu và nhấn nút "Dự báo".

Gửi dữ liệu lên server: Dữ liệu đầu vào được gửi lên server thông qua phương thức POST.

Tiền xử lý dữ liệu đầu vào: Ứng dụng Flask nhận dữ liệu, kiểm tra và chuyển đổi về đúng định dạng, đảm bảo các tên cột, kiểu dữ liệu trùng khớp với dữ liệu đã dùng để huấn luyện mô hình. Nếu cần, các bước chuẩn hóa, kiểm tra giá trị hợp lệ cũng được thực hiện ở đây.

Dự báo bằng mô hình AI: Dữ liệu sau khi xử lý được đưa vào mô hình AI đã nạp sẵn. Mô hình thực hiện dự báo và trả về kết quả (giá đóng cửa dự báo).

Trả kết quả về giao diện: Kết quả dự báo được gửi trả về giao diện web, hiển thị rõ ràng cho người dùng. Nếu có lỗi (ví dụ: thiếu dữ liệu, định dạng sai), hệ thống sẽ trả về thông báo hướng dẫn người dùng nhập lại.

3.3.4. Xử lý các vấn đề thực tiễn khi tích hợp

Trong quá trình tích hợp mô hình AI vào Flask, em đã gặp và giải quyết một số vấn đề thực tiễn như:

Đồng bộ tên cột: Đảm bảo tên các trường dữ liệu đầu vào khi dự báo phải trùng khớp với tên cột đã dùng khi huấn luyện mô hình (ví dụ: viết hoa/viết thường, thứ tự các cột).

Kiểm tra dữ liệu đầu vào: Xử lý các trường hợp người dùng nhập thiếu, nhập sai kiểu dữ liệu, hoặc nhập giá trị bất hợp lý để tránh lỗi khi dự báo.

Tối ưu hiệu năng: Nạp mô hình AI một lần duy nhất khi khởi động server thay vì nạp lại mỗi lần dự báo, giúp giảm thời gian phản hồi và tiết kiệm tài nguyên.

Bảo mật và ổn định: Hạn chế các lỗ hổng bảo mật cơ bản, kiểm soát lỗi và thông báo rõ ràng cho người dùng khi có sự cố.

3.3.5. Mở rộng và bảo trì hệ thống

Việc tích hợp mô hình AI vào Flask giúp hệ thống dễ dàng mở rộng trong tương lai. Có thể bổ sung thêm các mô hình mới, cho phép người dùng lựa chọn mô hình dự báo, hoặc tích hợp thêm các chức năng như lưu lịch sử dự báo, xuất báo cáo, kết nối với cơ sở dữ liệu lớn hơn hoặc các API tài chính thực tế.

Ngoài ra, việc sử dụng Flask – một framework phổ biến, tài liệu phong phú – giúp việc bảo trì, cập nhật hệ thống trở nên thuận tiện, dễ dàng cho em phát triển thêm sau này.

Tích hợp mô hình AI vào ứng dụng Flask là bước quan trọng giúp chuyển giao kết quả nghiên cứu từ môi trường học thuật sang ứng dụng thực tiễn, phục vụ nhu cầu dự báo giá cổ phiếu của người dùng. Nhờ quy trình tích hợp bài bản, hệ thống không chỉ đảm bảo độ chính xác, ổn định mà còn sẵn sàng cho việc mở rộng, phát triển trong tương lai, góp phần nâng cao giá trị ứng dụng của trí tuệ nhân tạo trong lĩnh vực tài chính – chứng khoán.

3.4. Đề xuất phát triển

3.4.1. Bài học kinh nghiệm

Qua quá trình thực nghiệm, em rút ra một số bài học quan trọng:

Việc tiền xử lý dữ liệu kỹ lưỡng, xây dựng các đặc trưng phù hợp có ảnh hưởng lớn đến hiệu quả dự báo của mô hình.

Các mô hình học máy hiện đại như Gradient Boosting, Random Forest có khả năng dự báo tốt hơn hẳn các mô hình tuyến tính truyền thống, đặc biệt với dữ liệu tài chính nhiều biến động.

Việc kiểm tra, đồng bộ tên cột và định dạng dữ liệu giữa quá trình huấn luyện và triển khai thực tế là rất quan trọng để tránh lỗi khi tích hợp mô hình vào hệ thống web.

Giao diện người dùng cần được thiết kế trực quan, có các thông báo hướng dẫn và kiểm tra dữ liệu đầu vào để nâng cao trải nghiệm và giảm thiểu lỗi thao tác.

3.4.2. Đề xuất phát triển hệ thống trong tương lai

Để nâng cao hơn nữa hiệu quả và giá trị ứng dụng của hệ thống, em đề xuất một số hướng phát triển như sau:

Mở rộng tập dữ liệu: Thu thập dữ liệu trong khoảng thời gian dài hơn, bổ sung thêm các mã cổ phiếu khác để hệ thống có thể dự báo đa dạng hơn, phục vụ nhiều đối tượng người dùng.

Tích hợp dữ liệu cơ bản và dữ liệu phi cấu trúc: Bổ sung các yếu tố cơ bản như báo cáo tài chính, chỉ số kinh tế vĩ mô, hoặc khai thác dữ liệu phi cấu trúc như tin tức, mạng xã hội để tăng cường khả năng dự báo, đặc biệt trong các giai đoạn thị trường biến động mạnh.

Áp dụng các mô hình học sâu (Deep Learning): Nghiên cứu và thử nghiệm các mô hình học sâu như LSTM, GRU, Transformer,… vốn được đánh giá cao trong các bài toán chuỗi thời gian tài chính.

Tối ưu hóa hiệu năng và bảo mật: Nâng cấp hệ thống để xử lý nhiều yêu cầu đồng thời, tối ưu hóa tốc độ phản hồi, đồng thời tăng cường các biện pháp bảo mật dữ liệu người dùng.

Phát triển các tính năng mở rộng: Cho phép người dùng lưu lại lịch sử dự báo, xuất báo cáo, hiển thị biểu đồ so sánh giá dự báo và giá thực tế, hoặc tích hợp với các nền tảng giao dịch thực tế.

Triển khai trên nền tảng đám mây: Đưa hệ thống lên các nền tảng cloud như AWS, Azure, Google Cloud để tăng khả năng mở rộng, phục vụ nhiều người dùng cùng lúc và đảm bảo tính sẵn sàng cao.

Việc đánh giá kết quả thực nghiệm giúp em kiểm chứng hiệu quả thực tế của hệ thống, đồng thời nhận diện các điểm mạnh, điểm yếu để tiếp tục hoàn thiện sản phẩm. Với nền tảng đã xây dựng, hệ thống dự báo giá cổ phiếu VCB ứng dụng AI có tiềm năng phát triển mạnh mẽ, không chỉ phục vụ nhu cầu học tập, nghiên cứu mà còn có thể ứng dụng thực tiễn trong lĩnh vực tài chính – chứng khoán, góp phần thúc đẩy quá trình chuyển đổi số và ứng dụng trí tuệ nhân tạo tại Việt Nam.

CHƯƠNG 4: KẾT QUẢ ĐÁNH GIÁ CÁC MÔ HÌNH

Sau khi huấn luyện, các mô hình Linear Regression, Random Forest và Gradient Boosting đều được kiểm tra trên tập dữ liệu kiểm tra (test set). Kết quả đánh giá được tổng hợp như sau:

Linear Regression: Mô hình này cho kết quả dự báo ở mức cơ bản, phù hợp với các dữ liệu có mối quan hệ tuyến tính rõ ràng. Tuy nhiên, do dữ liệu giá cổ phiếu thường có tính phi tuyến và chịu ảnh hưởng của nhiều yếu tố phức tạp, Linear Regression thường cho R2 thấp hơn, RMSE và MAE cao hơn so với các mô hình phức tạp hơn.

Random Forest Regressor: Nhờ khả năng học các mối quan hệ phi tuyến và chống overfitting tốt, Random Forest thường cho kết quả dự báo chính xác hơn Linear Regression. Các chỉ số R2, RMSE, MAE đều được cải thiện rõ rệt. Mô hình này cũng khá ổn định khi xử lý dữ liệu có nhiễu hoặc ngoại lệ.

Gradient Boosting Regressor: Đây là mô hình có hiệu quả dự báo tốt nhất trong số các mô hình được thử nghiệm. Gradient Boosting có khả năng tối ưu hóa sai số dự báo, học sâu các đặc trưng quan trọng trong dữ liệu, nhờ đó cho kết quả R2 cao nhất, RMSE và MAE thấp nhất. Tuy nhiên, thời gian huấn luyện và dự báo của mô hình này thường lâu hơn so với Random Forest và Linear Regression.

Bảng tổng hợp kết quả đánh giá các mô hình (ví dụ):

Bảng 4.1. So sánh chỉ số RMSE, MAE, R^2 giữa các mô hình

```
=== SO SÁNH CÁC MÔ HÌNH ===
                        R2         RMSE         MAE           MSE
Model
Linear Regression  0.988989   378.089436  295.905475  1.429516e+05
Random Forest      0.875109  1273.346233  843.333782  1.621411e+06
Gradient Boosting  0.887580  1208.100609  798.851798  1.459507e+06
LSTM               0.751117  1800.430813 1428.499399  3.241551e+06
```

Phân tích và so sánh kết quả :

Từ kết quả thu được, có thể thấy các mô hình học máy hiện đại như Random Forest, Gradient Boosting và LSTM đều cho độ chính xác dự báo cao hơn đáng kể so với mô hình hồi quy tuyến tính (Linear Regression). Mỗi mô hình có đặc điểm riêng, phù hợp với từng loại bài toán và mục tiêu sử dụng khác nhau.

- **Linear Regression** có ưu điểm là đơn giản, dễ triển khai và dễ giải thích kết quả. Tuy nhiên, mô hình này giả định mối quan hệ tuyến tính giữa các biến, do đó không phù hợp với dữ liệu tài chính vốn thường mang tính phi tuyến, có nhiều yếu tố ảnh hưởng đan xen và biến động mạnh theo thời gian.

- **Random Forest** là mô hình tổ hợp mạnh mẽ, có khả năng xử lý tốt các mối quan hệ phi tuyến giữa các biến. Mô hình này cho kết quả dự báo khá chính xác, thời gian huấn luyện nhanh hơn Gradient Boosting và ít bị overfitting. Đây là lựa chọn phù hợp cho các hệ thống yêu cầu tính ổn định, tốc độ và khả năng mở rộng.

- **Gradient Boosting** là mô hình cho kết quả dự báo tốt nhất trong số các mô hình học máy truyền thống được thử nghiệm. Mô hình này hoạt động hiệu quả trên các tập dữ liệu phức tạp, có nhiều đặc trưng phi tuyến và nhiễu. Tuy nhiên, nhược điểm của Gradient Boosting là yêu cầu nhiều tài nguyên tính toán, thời gian huấn luyện lâu hơn và khó điều chỉnh tham số hơn so với Random Forest.

- **LSTM (Long Short-Term Memory)** là mô hình học sâu (Deep Learning) thuộc loại mạng nơ-ron hồi tiếp (RNN), được thiết kế đặc biệt để xử lý chuỗi thời gian. LSTM có khả năng ghi nhớ thông tin dài hạn và nhận diện các xu hướng, mẫu lặp trong dữ liệu theo thời gian. Mô hình này tỏ ra rất hiệu quả với dữ liệu tài chính do có thể học được sự phụ thuộc theo chuỗi. Tuy nhiên, LSTM cũng yêu cầu khối lượng dữ liệu lớn, thời gian huấn luyện dài và khó giải thích kết quả hơn so với các mô hình học máy truyền thống.

Kết luận, việc lựa chọn mô hình cuối cùng phụ thuộc vào mục tiêu và điều kiện triển khai thực tế:

- Nếu **ưu tiên độ chính xác và khả năng học sâu các đặc điểm phức tạp**, **Gradient Boosting** là lựa chọn tối ưu trong điều kiện dữ liệu vừa phải.

- Nếu **làm việc với dữ liệu chuỗi thời gian dài** và muốn khai thác các **xu hướng theo thời gian**, **LSTM** là mô hình phù hợp, đặc biệt trong các nghiên cứu mở rộng.

- Nếu **cần sự cân bằng giữa hiệu quả, độ chính xác và tốc độ xử lý**, **Random Forest** là một giải pháp hợp lý.
- **Linear Regression** có thể được dùng như một mô hình tham chiếu cơ bản để so sánh với các mô hình phức tạp hơn.

Trong đồ án này, em lựa chọn **Gradient Boosting** làm mô hình chính cho hệ thống dự báo giá cổ phiếu Vietcombank (VCB) do độ chính xác cao và khả năng xử lý tốt dữ liệu phi tuyến. Các mô hình còn lại như **LSTM, Random Forest** và **Linear Regression** vẫn được huấn luyện và lưu giữ để phục vụ mục đích so sánh, kiểm chứng và làm nền tảng cho các hướng nghiên cứu phát triển trong tương lai.

TÀI LIỆU THAM KHẢO

[1] C. M. Bishop, *Pattern Recognition and Machine Learning*, New York: Springer, 2006.

[2] G. James, D. Witten, T. Hastie, and R. Tibshirani, “Linear regression,” in *An Introduction to Statistical Learning*, Springer, 2013, pp. 59–122.

[3] Scikit-learn Developers, “Linear models,” *Scikit-learn Documentation*, [Online]. Available: https://scikit-learn.org/stable/modules/linear_model.html. [Accessed: Jul. 3, 2025].

[4] A. Ng, “Machine Learning,” *Coursera Online Course*, Stanford University, 2018. [Online]. Available: https://www.coursera.org/learn/machine-learning

[5] J. Brownlee, “A Gentle Introduction to Linear Regression,” *Machine Learning Mastery*, 2018. [Online]. Available: https://machinelearningmastery.com/linear-regression-for-machine-learning/

[6] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.

[7] S. Rashmi and H. Bhushan, “A Comprehensive Review of Gradient Boosting Algorithms,” *International Journal of Advanced Research in Computer Science*, vol. 9, no. 5, 2018.

[8] Google Developers, “Gradient Boosted Decision Trees,” *Google Developers ML Crash Course*, [Online]. Available: https://developers.google.com/machine-learning/gradient-boosted-trees/. [Accessed: Jul. 3, 2025].

[9] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[10] F. Chollet, *Deep Learning with Python*, 2nd ed., Shelter Island, NY: Manning Publications, 2021.

[11] TensorFlow Developers, “Recurrent Neural Networks (RNN) with Keras,” *TensorFlow Documentation*, [Online]. Available: https://www.tensorflow.org/guide/keras/rnn. .

[12] M. J. Nichols, “Understanding LSTM Networks,” *Colah’s Blog*, 2015. [Online]. Available: https://colah.github.io/posts/2015-08-Understanding-LSTMs/.

[13] N. T. Tuan, “Deep learning cơ bản – Bài 14: Long Short-Term Memory (LSTM),” *nttuan8.com*, [Online]. Available: https://nttuan8.com/bai-14-long-short-term-memory-lstm/.

[14] H. T. X. Nguyen, “Nhóm 9 - Dự đoán giá chứng khoán,” *YouTube*, 2023. [Online Video]. Available: https://youtu.be/d8h3k4W7a8M?si=bshT2j7Os7-u4rFg.

[15] TUYEN268KK, “Prediction of Vietcombank stock prices by SARIMA,” *Kaggle Notebooks*, 2024. [Online]. Available: https://www.kaggle.com/code/tuyen268kk/prediction-of-vietcombank-stock-prices-by-sarima.

PHỤ LỤC

Các hình ảnh khi sử dụng thực tế

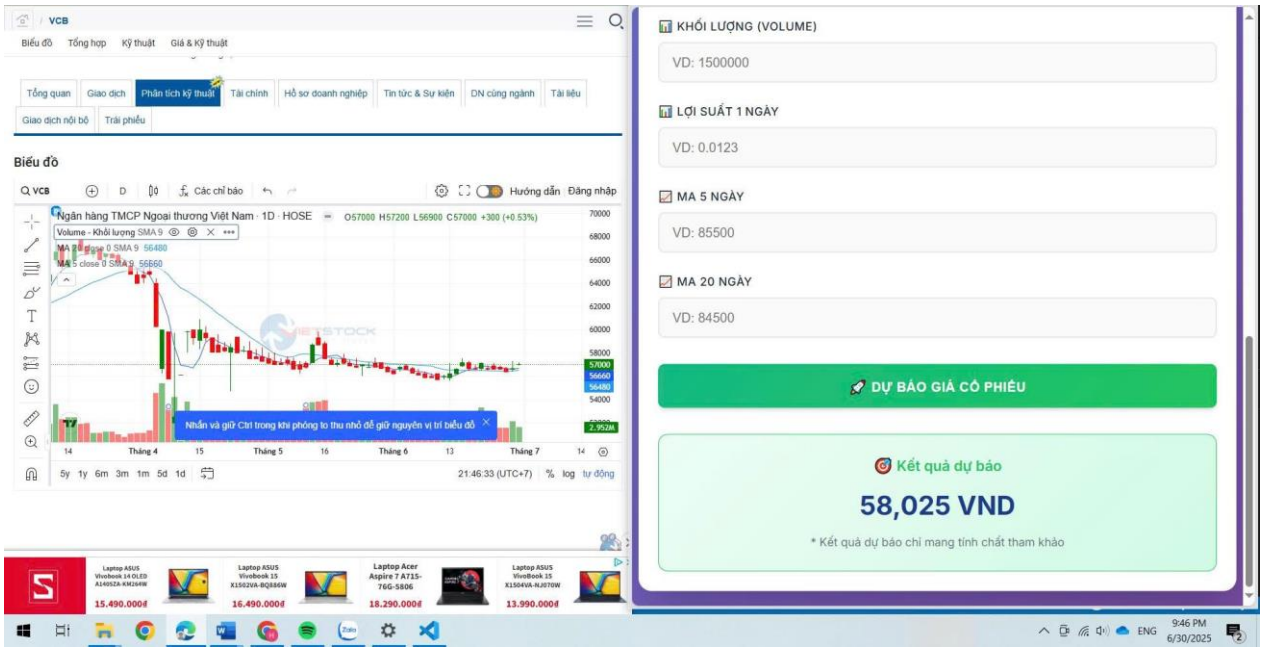

Hình PL.1. Ảnh chụp dự báo ngày 30/6/2025

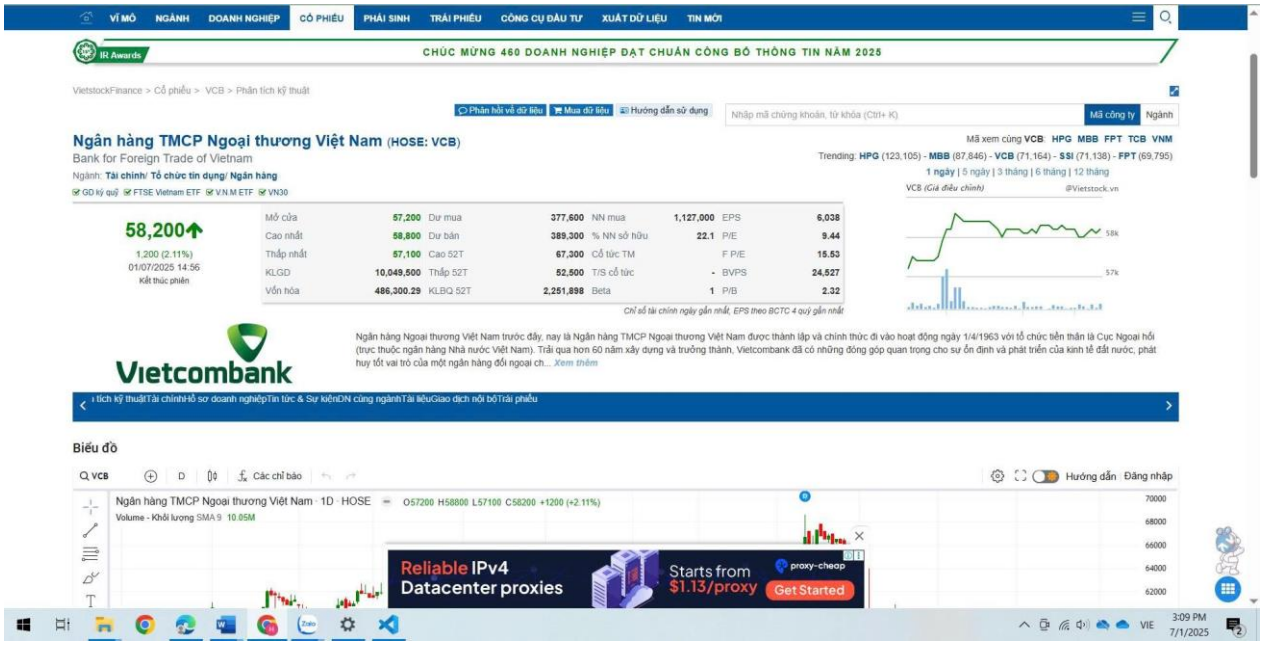

Hình PL.2. Ảnh chụp dự báo ngày 1/7/2025